



ĐẠI HỌC QUỐC GIA TP.HCM
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - TIN HỌC

Báo cáo đồ án cuối kỳ Môn Hệ thống tư vấn

Đề tài:
Xây dựng Hệ thống tư vấn lai cho sản phẩm Sữa rửa mặt
trên sàn thương mại điện tử kết hợp Lọc dựa trên nội dung,
Lọc cộng tác và Đề xuất phổ biến

Giảng viên hướng dẫn:
ThS. Huỳnh Thành Sơn

Người thực hiện:

Nguyễn Công Tiến Dũng	MSSV: 22280014
Trảo An Huy	MSSV: 22280041
Đinh Xuân Khang	MSSV: 22280042

Lời cảm ơn

Trước hết, nhóm chúng em xin gửi lời cảm ơn sâu sắc và chân thành nhất đến **Thầy Huỳnh Thanh Sơn** – giảng viên hướng dẫn môn Hệ thống tư vấn. Thầy không chỉ truyền đạt cho nhóm những kiến thức chuyên môn quý báu, mà còn luôn tận tình hỗ trợ, định hướng và tạo điều kiện thuận lợi để nhóm có thể triển khai và hoàn thành đồ án một cách hiệu quả nhất. Sự tận tâm và tinh thần trách nhiệm của Thầy chính là nguồn động lực lớn để nhóm chúng em nỗ lực hơn trong quá trình học tập và nghiên cứu.

Trong quá trình thực hiện đồ án, nhóm cũng đã nhận được nhiều sự hỗ trợ gián tiếp từ các cộng đồng lập trình và công nghệ như **GitHub**, **Stack Overflow**, **ChatGPT**, cũng như nhiều nguồn tài liệu học thuật trực tuyến khác. Đây là những nền tảng quý giá giúp nhóm mở rộng kiến thức, giải quyết các vấn đề kỹ thuật phát sinh và nâng cao chất lượng của hệ thống tư vấn mà nhóm xây dựng.

Nhóm cũng xin gửi lời cảm ơn chân thành đến **Khoa Toán - Tin học**, Trường **Đại học Khoa Học Tự Nhiên**, vì đã tạo ra một môi trường học tập năng động, cung cấp đầy đủ cơ sở vật chất, tài liệu và điều kiện để sinh viên có thể nghiên cứu, học hỏi và áp dụng kiến thức vào thực tiễn.

Cuối cùng, nhóm xin cảm ơn các thành viên trong nhóm vì tinh thần trách nhiệm, sự hợp tác tích cực và sự kiên trì trong suốt quá trình làm việc. Những khó khăn và thử thách đã trở thành cơ hội để mỗi thành viên phát triển kỹ năng, hiểu rõ hơn về công việc nhóm và trau dồi tư duy giải quyết vấn đề một cách thực tiễn và hiệu quả.

Một lần nữa, nhóm xin chân thành cảm ơn tất cả những người đã góp phần vào sự thành công của đồ án này.

Lời mở đầu

Trong bối cảnh **thương mại điện tử** đang ngày càng phát triển mạnh mẽ, người tiêu dùng có thể dễ dàng tiếp cận hàng nghìn sản phẩm chỉ qua vài cú nhấp chuột. Tuy nhiên, chính sự **đa dạng và phong phú của sản phẩm** lại tạo ra một thách thức lớn: người dùng dễ cảm thấy bối rối và mất nhiều thời gian để lựa chọn sản phẩm phù hợp với nhu cầu cá nhân. Điều này đặc biệt đối với các mặt hàng chăm sóc cá nhân như sữa rửa mặt, bởi lẽ mỗi cá nhân có **làn da và sở thích khác nhau**, đòi hỏi sự **tư vấn mang tính cá nhân hóa cao**.

Trước yêu cầu đó, các hệ thống gợi ý/tư vấn (**recommender systems**) đã trở thành một phần không thể thiếu trong các nền tảng thương mại điện tử hiện đại. Trong đồ án này, nhóm chúng em lựa chọn xây dựng một hệ thống tư vấn cho sản phẩm sữa rửa mặt nhằm hỗ trợ người dùng trong việc tìm kiếm và lựa chọn sản phẩm phù hợp một cách hiệu quả hơn. Hệ thống được thiết kế dưới dạng một mô hình lai, kết hợp sức mạnh của phương pháp **lọc dựa trên nội dung (content-based filtering)**, **lọc cộng tác (collaborative filtering)**, và **đề xuất dựa trên độ phổ biến (popularity-based recommendation)** để đưa ra gợi ý chính xác và cá nhân hóa hơn.

Đồ án tập trung vào việc thu thập, xử lý và phân tích dữ liệu liên quan đến người dùng và sản phẩm sữa rửa mặt trên nền tảng thương mại điện tử Shopee, xây dựng mô hình tư vấn và đánh giá hiệu quả của hệ thống đề xuất. Qua đó, nhóm hy vọng có thể cung cấp một giải pháp hỗ trợ hữu ích cho người tiêu dùng, đồng thời làm rõ hơn vai trò của hệ thống tư vấn trong việc nâng cao trải nghiệm mua sắm trực tuyến.

Đồ án tập trung vào việc thu thập, xử lý và phân tích dữ liệu liên quan đến người dùng và sản phẩm sữa rửa mặt từ nền tảng thương mại điện tử Shopee, xây dựng mô hình tư vấn, và đánh giá hiệu quả của hệ thống đề xuất. Qua đó, nhóm hy vọng có thể cung cấp một giải pháp hỗ trợ hữu ích cho người tiêu dùng, đồng thời làm rõ hơn vai trò của hệ thống tư vấn trong việc nâng cao trải nghiệm mua sắm trực tuyến.

Đồ án không chỉ là cơ hội để nhóm áp dụng các kiến thức đã học về máy học, khai thác dữ liệu và cơ sở dữ liệu, mà còn giúp rèn luyện kỹ năng làm việc nhóm, kỹ năng giải quyết vấn đề thực tế và khả năng tiếp cận các xu hướng công nghệ mới trong lĩnh vực thương mại điện tử.

Mục lục

Lời cảm ơn	i
Lời mở đầu	ii
Danh sách bảng	v
Danh sách hình vẽ	vi
1 Giới thiệu	1
1.1 Giới thiệu chung	1
1.2 Mục tiêu của đồ án	2
1.2.1 Xây dựng một Hệ thống tư vấn lai (Hybrid Recommender System): .	2
1.2.2 Nâng cao trải nghiệm người dùng (User Experience):	2
1.2.3 Khai thác và xử lý dữ liệu thực tế:	2
1.2.4 Đánh giá và kiểm chứng hiệu quả mô hình:	3
1.3 Các hướng tiếp cận liên quan	3
1.4 Đề xuất hướng giải quyết	3
1.4.1 Đề xuất mô hình hệ thống tư vấn lai kết hợp lọc nội dung, lọc cộng tác và đề xuất phổ biến	3
2 Cơ sở lý thuyết	6
2.1 Tổng quan Hệ thống tư vấn	6
2.1.1 Giới thiệu Recommendation System	6
2.1.2 Một số thách thức khi triển khai hệ thống khuyến nghị	8
2.2 Lọc dựa trên nội dung (Content-Based Filtering)	9
2.2.1 Cách tiếp cận tổng quát	9
2.2.2 Ứng dụng với tập dữ liệu ViEcomRec	9
2.2.3 Ưu điểm và hạn chế	10
2.2.4 Kết luận	10
2.3 Lọc cộng tác (Collaborative Filtering)	10
2.3.1 Giới thiệu và các Thách thức chung của Lọc Cộng tác	11
2.3.2 Lọc Cộng tác Dựa trên Láng Giềng (Neighborhood-Based CF) . . .	12
2.4 Đề xuất dựa trên độ phổ biến	21
2.4.1 Nguyên lý hoạt động	21
2.4.2 Ứng dụng với tập dữ liệu ViEcomRec	21
2.4.3 Đánh giá ưu điểm và hạn chế	22
2.4.4 Vai trò trong hệ thống tư vấn	22
2.5 Phương pháp biểu diễn đặc trưng (Embedding Techniques)	22

2.5.1	TF-IDF (Term Frequency – Inverse Document Frequency)	23
2.5.2	Word Embedding	23
2.5.3	Sentence Embedding	24
2.6	Độ đo tương đồng (Cosine Similarity) trong hệ thống tư vấn	28
2.6.1	Cosine Similarity là gì?	28
2.6.2	Ứng dụng trong hệ thống đề xuất content-based	29
2.7	Phương pháp đánh giá hệ thống gợi ý	29
2.7.1	Giới thiệu chung về Đánh giá Hệ thống Gợi ý	29
2.7.2	Các Độ đo Đánh giá Offline được sử dụng	30
3	Dữ liệu và phương pháp triển khai	33
3.1	Mô tả tập dữ liệu ViEcomRec	33
3.1.1	Nguồn gốc và Mục tiêu của Tập dữ liệu	33
3.1.2	Quy trình Thu thập Dữ liệu (Dataset Crawling)	34
3.1.3	Trích xuất Thuộc tính Sản phẩm (Attribute Extraction)	34
3.1.4	Thống kê Tập dữ liệu	35
3.2	Khám Phá Dữ liệu (EDA)	36
3.2.1	Phân phối về giá và đánh giá sản phẩm	36
3.2.2	Mối liên hệ giữa các thuộc tính	37
3.3	Chuẩn bị dữ liệu	37
3.3.1	Xây dựng dữ liệu cho Lọc dựa trên nội dung	37
3.3.2	Xây dựng dữ liệu sản phẩm phổ biến	38
3.4	Các phương pháp và mô hình triển khai	38
3.4.1	Áp dụng Lọc dựa trên nội dung (Content-Based Filtering)	38
3.4.2	Áp dụng Lọc cộng tác dựa trên người dùng (User-Based CF)	39
3.4.3	Áp dụng Đề xuất dựa trên độ phổ biến (Popularity-Based)	39
3.4.4	Xây dựng mô hình lai (Hybrid Model)	39
3.5	Thiết kế Hệ thống tổng thể	40
4	Thực nghiệm và đánh giá	42
4.1	Mô tả kịch bản thực nghiệm	42
4.2	Thiết lập và thông số mô hình	42
4.3	Kết quả gợi ý với phương pháp lọc nội dung	43
4.4	Kết quả gợi ý với phương pháp Đề xuất dựa trên độ phổ biến	43
4.5	Đánh giá hiệu quả Mô hình Lọc cộng tác	44
4.6	Nhận xét và phân tích kết quả	44
5	Thảo luận và Kết luận	45
5.1	Thảo luận	45
5.2	Kết luận	46
5.3	Hướng phát triển	46
	Tài liệu tham khảo	49

Danh sách bảng

2.1	So sánh các phương pháp biểu diễn văn bản	27
3.1	Thống kê tập dữ liệu ViEcomRec.	35
3.2	Ví dụ dữ liệu tương tác người dùng và sản phẩm.	38
4.1	So sánh hiệu quả giữa các phương pháp đề xuất xếp hạng.	44
5.1	So sánh tổng quan các phương pháp đề xuất.	45

Danh sách hình vẽ

2.1	Tổng quan Hệ thống tư vấn	6
2.2	Ví dụ lọc dựa trên nội dung	8
2.3	Ví dụ Cosine Similarity trong không gian 2D	28
3.1	Phân phối của giá sản phẩm trong tập dữ liệu.	36
3.2	Phân phối về lượng đánh giá trung bình của sản phẩm.	36
3.3	Mối liên hệ giữa giá và số lượng bán ra.	37
3.4	Mô hình lai áp dụng cho người dùng cũ.	40
3.5	Tổng quan luồng hoạt động của hệ thống đề xuất.	41
3.6	Kiến trúc hệ thống đề xuất.	41

Chương 1

Giới thiệu

1.1 Giới thiệu chung

Trong thời đại công nghệ số phát triển nhanh chóng, thương mại điện tử đã trở thành một kênh mua sắm phổ biến, tiện lợi và hiệu quả đối với người tiêu dùng. Với số lượng sản phẩm ngày càng đa dạng, người dùng có nhiều lựa chọn hơn bao giờ hết, nhưng điều này cũng đặt ra thách thức trong việc ra quyết định khi phải đối mặt với quá nhiều thông tin. Đặc biệt trong lĩnh vực **mỹ phẩm và chăm sóc da**, sự lựa chọn sai sản phẩm có thể gây ảnh hưởng trực tiếp đến sức khỏe và trải nghiệm cá nhân của người dùng.

Sữa rửa mặt là một trong những sản phẩm chăm sóc da cơ bản nhưng quan trọng, với nhiều loại phù hợp cho từng loại da, giới tính, độ tuổi và nhu cầu sử dụng khác nhau. Tuy nhiên, việc lựa chọn được sản phẩm phù hợp vẫn là điều khó khăn đối với người tiêu dùng khi mua hàng trực tuyến, do thiếu thông tin cá nhân hóa hoặc không có người tư vấn trực tiếp.

Trong bối cảnh đó, các **hệ thống tư vấn (Recommendation Systems)** đóng vai trò quan trọng trong việc hỗ trợ người dùng đưa ra lựa chọn hợp lý, tiết kiệm thời gian và nâng cao trải nghiệm mua sắm. Trong đề tài này, nhóm nghiên cứu đề xuất xây dựng một hệ thống tư vấn cho sản phẩm sữa rửa mặt, ứng dụng **phương pháp lọc cộng tác dựa trên nội dung (Content-Based Collaborative Filtering)** [1] – một hướng tiếp cận kết hợp giữa hành vi người dùng và đặc trưng nội dung sản phẩm để đưa ra gợi ý phù hợp.

Đề tài không chỉ có ý nghĩa thực tiễn trong việc hỗ trợ hoạt động kinh doanh trực tuyến, mà còn góp phần làm rõ hơn về cách thức ứng dụng các phương pháp học máy và khai thác dữ liệu trong việc xây dựng hệ thống thông minh hỗ trợ ra quyết định.

1.2 Mục tiêu của đề án

Đề án này được thực hiện nhằm giải quyết các thách thức trong việc lựa chọn sản phẩm trên sàn thương mại điện tử bằng cách xây dựng một hệ thống tư vấn thông minh và hiệu quả. Các mục tiêu cụ thể được đặt ra như sau:

1.2.1 Xây dựng một Hệ thống tư vấn lai (Hybrid Recommender System):

Mục tiêu cốt lõi là **thiết kế và triển khai một hệ thống lai**, kết hợp sức mạnh của nhiều phương pháp đề xuất để **tối ưu hóa độ chính xác và khả năng cá nhân hóa**. Cụ thể, hệ thống sẽ tích hợp:

- **Lọc dựa trên nội dung (Content-Based Filtering):** Khai thác sâu các đặc trưng của sản phẩm (loại da, thành phần, công dụng, thương hiệu) và lịch sử tương tác của người dùng để đưa ra gợi ý phù hợp với hồ sơ và sở thích rõ ràng của người dùng.
- **Lọc cộng tác (Collaborative Filtering):** Phân tích hành vi tương tác của người dùng (ví dụ: lượt mua, đánh giá) để tìm ra các sản phẩm tương tự hoặc những người dùng có cùng sở thích, từ đó khám phá các gợi ý mới mà phương pháp dựa trên nội dung có thể bỏ lỡ.
- **Đề xuất dựa trên độ phổ biến (Popularity-Based Recommendation):** Sử dụng như một chiến lược nền tảng để giải quyết "**vấn đề khởi động nguội** (cold start)", đảm bảo người dùng mới luôn nhận được những gợi ý an toàn và phù hợp với xu hướng chung.

1.2.2 Nâng cao trải nghiệm người dùng (User Experience):

- **Giảm thiểu thời gian và công sức tìm kiếm** cho người dùng.
- **Tăng mức độ hài lòng và tin cậy** vào các gợi ý của hệ thống, từ đó **thúc đẩy quyết định mua hàng và giữ chân khách hàng**.

1.2.3 Khai thác và xử lý dữ liệu thực tế:

- Áp dụng các kỹ thuật **xử lý ngôn ngữ tự nhiên (NLP) tiên tiến** để trích xuất các đặc trưng có ý nghĩa từ dữ liệu văn bản tiếng Việt (chẳng hạn như tên, mô tả sản phẩm) trên tập dữ liệu **ViEcomRec**.
- **Xây dựng hồ sơ người dùng (user profile)** linh hoạt, được cập nhật dựa trên lịch sử tương tác (cho cả lọc nội dung và lọc cộng tác).
- **Xử lý ma trận tương tác người dùng - sản phẩm** cho lọc cộng tác.

1.2.4 Đánh giá và kiểm chứng hiệu quả mô hình:

- Thiết lập một **quy trình thực nghiệm bài bản** để so sánh và đánh giá hiệu quả của từng phương pháp riêng lẻ và của mô hình lai.
- Sử dụng các **độ đo định lượng (như Recall@k, MRR@k, NDCG@k)** để chứng minh tính ưu việt của giải pháp đề xuất.

1.3 Các hướng tiếp cận liên quan

Từ những khó khăn và thách thức trong việc hỗ trợ người dùng lựa chọn sản phẩm phù hợp trên nền tảng **thương mại điện tử**, đặc biệt là với các mặt hàng mang tính **cá nhân hóa cao** như sữa rửa mặt, nhiều phương pháp đã được nghiên cứu và ứng dụng trong việc xây dựng hệ thống tư vấn sản phẩm.

Đề xuất dựa trên mức độ phổ biến (Popularity-Based Recommendation) là một trong những phương pháp cơ bản và dễ triển khai. Phương pháp này hoạt động bằng cách thống kê các sản phẩm được tương tác nhiều nhất và đề xuất chúng cho tất cả người dùng. Ưu điểm là đơn giản, nhưng thiếu cá nhân hóa.

Lọc dựa trên nội dung (Content-Based Filtering) xây dựng hồ sơ người dùng dựa trên đặc điểm của sản phẩm mà họ đã tương tác, sau đó tìm kiếm các sản phẩm mới có đặc điểm tương đồng. Phương pháp này mang lại tính cá nhân hóa cao hơn, đặc biệt hữu ích khi người dùng có nhu cầu rõ ràng. Tuy nhiên, nó có thể hạn chế khả năng khám phá sản phẩm mới.

Lọc cộng tác (Collaborative Filtering) dựa trên giả định rằng những người dùng có hành vi tương tự trong quá khứ sẽ có sở thích tương tự trong tương lai (user-based), hoặc những sản phẩm được người dùng tương tự đánh giá cao sẽ phù hợp (item-based). Phương pháp này có khả năng khám phá tốt hơn lọc nội dung nhưng gặp vấn đề với người dùng/sản phẩm mới (**cold start**) và dữ liệu thưa thớt.

Trong phạm vi đề tài này, nhóm lựa chọn kết hợp cả ba hướng tiếp cận: **đề xuất phổ biến**, **lọc dựa trên nội dung**, và **lọc cộng tác**, nhằm phát huy thế mạnh của từng phương pháp và giảm thiểu hạn chế của chúng.

1.4 Đề xuất hướng giải quyết

1.4.1 Đề xuất mô hình hệ thống tư vấn lai kết hợp lọc nội dung, lọc cộng tác và đề xuất phổ biến

Nhằm giải quyết những vấn đề trên, nhóm đề xuất xây dựng **hệ thống tư vấn lai** kết hợp giữa phương pháp **lọc dựa trên nội dung (Content-Based Filtering)**, **lọc cộng tác (Collaborative Filtering)** và **đề xuất phổ biến (Popularity-Based Recommendation)** theo hướng sau:

a) Lọc dựa trên nội dung

Hệ thống sẽ xây dựng **hồ sơ người dùng (user profile)** dựa trên các thông tin cá nhân thu thập được từ lịch sử tương tác và đánh giá của người dùng với các sản phẩm, sau đó sử dụng hồ sơ này để tìm kiếm các sản phẩm mới có đặc điểm tương đồng.

Mỗi sản phẩm sữa rửa mặt sẽ được biểu diễn bằng một **vector đặc trưng** gồm các thông tin như: tên sản phẩm, thương hiệu, nhãn hàng, loại sản phẩm, loại da phù hợp, mô tả chi tiết sản phẩm,... Từ đó, hệ thống sử dụng mô hình tính **độ tương đồng (cosine similarity)** giữa hồ sơ người dùng và các sản phẩm để đưa ra gợi ý phù hợp.

b) Lọc cộng tác

Hệ thống phân tích **ma trận tương tác người dùng - sản phẩm** (ví dụ: lượt mua, đánh giá) để tìm ra những người dùng có sở thích tương tự (**user-based CF**) hoặc những sản phẩm thường được mua/đánh giá cùng nhau (**item-based CF**). Từ đó, hệ thống có thể gợi ý những sản phẩm mà người dùng có thể thích dựa trên hành vi của những người dùng tương đồng hoặc các sản phẩm tương tự với những gì họ đã thích.

c) Đề xuất dựa trên độ phổ biến

Đối với **người dùng mới** hoặc khi thiếu dữ liệu lịch sử, hệ thống sẽ ưu tiên hiển thị các sản phẩm phổ biến, dựa trên thống kê lượt mua, lượt đánh giá hoặc mức độ yêu thích trung bình của cộng đồng người dùng. Phương pháp này giúp giảm thiểu ảnh hưởng của **vấn đề khởi động nguội (cold start)**, đồng thời đảm bảo rằng người dùng luôn có danh sách gợi ý đáng tin cậy trong quá trình tương tác đầu tiên.

d) Kết hợp ba phương pháp

Hệ thống sẽ kết hợp kết quả từ ba phương pháp trên. Ví dụ:

- **Với người dùng mới:** Ưu tiên đề xuất phổ biến, có thể kết hợp với một số gợi ý dựa trên nội dung nếu người dùng cung cấp thông tin ban đầu (loại da, vấn đề da).
- **Với người dùng hiện tại:**
 - Kết hợp điểm số từ lọc nội dung (dựa trên hồ sơ người dùng) và lọc cộng tác (dựa trên hành vi tương tác).
 - Sản phẩm phổ biến có thể được dùng để tăng cường hoặc làm phong phú thêm danh sách gợi ý, đặc biệt khi các phương pháp cá nhân hóa không tìm thấy đủ kết quả.
 - Trọng số của mỗi phương pháp có thể được điều chỉnh động dựa trên lượng dữ liệu tương tác của người dùng.

1.4.2 Kết quả kỳ vọng

Hệ thống tư vấn được đề xuất kỳ vọng sẽ mang lại các lợi ích sau:

- Giúp người dùng nhanh chóng chọn được sản phẩm sữa rửa mặt phù hợp, nhờ gợi ý có tính **cá nhân hóa cao**, khả năng khám phá tốt và minh bạch trong tiêu chí gợi ý.
- **Tối ưu hóa trải nghiệm người dùng** trên sàn thương mại điện tử, tăng sự hài lòng và khả năng quay lại mua sắm/sử dụng dịch vụ.
- **Giải quyết hiệu quả vấn đề dữ liệu thừa thớt và khởi động nguội** nhờ sự kết hợp linh hoạt giữa các phương pháp.
- **Nâng cao giá trị thực tiễn của hệ thống**, tạo tiền đề để mở rộng sang các nhóm sản phẩm khác trong lĩnh vực chăm sóc cá nhân hoặc mỹ phẩm.

Chương 2

Cơ sở lý thuyết

2.1 Tổng quan Hệ thống tư vấn

2.1.1 Giới thiệu Recommendation System

Trong thời đại bùng nổ dữ liệu và công nghệ số, người dùng có thể dễ dàng tiếp cận hàng triệu sản phẩm, bài viết, bộ phim hay dịch vụ chỉ bằng một vài thao tác đơn giản trên nền tảng trực tuyến. Tuy nhiên, chính sự phong phú này lại đặt ra một thách thức lớn: **làm thế nào để người dùng tìm được thông tin hoặc sản phẩm phù hợp nhất với nhu cầu của mình một cách nhanh chóng và hiệu quả?** Câu trả lời đến từ **hệ thống tư vấn (Recommender System)** – một thành phần quan trọng trong các nền tảng số hiện đại.

Hệ thống tư vấn là một dạng hệ thống thông minh có khả năng **phân tích hành vi người dùng và dữ liệu sản phẩm để đưa ra các gợi ý mang tính cá nhân hóa**. Mục tiêu của hệ thống là giúp người dùng giảm thiểu thời gian tìm kiếm, nâng cao trải nghiệm và đồng thời hỗ trợ doanh nghiệp tăng khả năng bán hàng hoặc duy trì tương tác người dùng. Trong **Hình 2.1** đã mô tả một cách tổng quát quy trình hoạt động của Hệ thống tư vấn.

Ngày nay, hệ thống tư vấn được ứng dụng rộng rãi trong nhiều lĩnh vực như:

- **Thương mại điện tử:** Gợi ý sản phẩm phù hợp trên Shopee, Lazada, Tiki...
- **Giải trí:** Gợi ý phim, nhạc, sách trên Netflix, Spotify, YouTube...
- **Mạng xã hội:** Gợi ý bạn bè, nhóm, bài viết trên Facebook, TikTok...



Hình 2.1: Tổng quan Hệ thống tư vấn

- **Giáo dục và việc làm:** Gợi ý khóa học trên Coursera, việc làm trên LinkedIn...

Tùy vào cách thức thu thập, xử lý dữ liệu và chiến lược mô hình hóa, các hệ thống tư vấn hiện đại có thể được chia thành các nhóm phương pháp chính như sau:

1. Lọc cộng tác (Collaborative Filtering):

Phương pháp này dựa trên hành vi tương tác của người dùng, như lượt đánh giá, lượt mua hoặc lượt xem. Giả định cốt lõi là "người dùng có hành vi tương tự sẽ có sở thích tương tự". Lọc cộng tác thường có hai biến thể chính:

- (a) **Dựa trên người dùng (User-based):** Gợi ý sản phẩm dựa trên người dùng có hành vi tương tự.
- (b) **Dựa trên sản phẩm (Item-based):** Gợi ý sản phẩm tương tự với những sản phẩm người dùng đã quan tâm.

2. Phân rã ma trận (Matrix Factorization) [2]:

Đây là một nhóm kỹ thuật học máy dùng để phân rã ma trận tương tác giữa người dùng và sản phẩm thành các vector đặc trưng ẩn (latent features). Phương pháp nổi bật trong nhóm này là **Singular Value Decomposition (SVD)** và **Alternating Least Squares (ALS)**, thường đạt hiệu quả cao trong các bài toán lọc cộng tác, đặc biệt là với dữ liệu thưa.

3. Lọc dựa trên nội dung (Content-Based Filtering):

Phương pháp này khai thác các đặc trưng mô tả của sản phẩm (ví dụ: loại da phù hợp, thành phần, thương hiệu...) và sở thích đã biết của người dùng để gợi ý các sản phẩm tương tự. Hồ sơ người dùng (user profile) được xây dựng từ các sản phẩm đã tương tác và được dùng để tính độ tương đồng với sản phẩm mới.

Hình 2.2 là một ví dụ điển hình trong Content-Based Filtering. một người rất thích ăn cam, vậy thì hệ thống gợi ý một loại trái cây tương tự với cam, ở đây là bưởi để đề xuất. Cách tiếp cận này yêu cầu việc sắp xếp các items vào từng nhóm hoặc đi tìm các đặc trưng của từng item.

4. Hệ thống tư vấn dựa trên tri thức (Knowledge-Based Recommendation) [3]:


Phương pháp này không dựa vào lịch sử hành vi, mà dựa vào các quy tắc, ràng buộc và thông tin rõ ràng về người dùng để đưa ra gợi ý. Hệ thống hoạt động giống như một chuyên gia tư vấn, đặc biệt hiệu quả trong các tình huống cold-start hoặc khi sản phẩm mang tính đặc thù cao như bất động sản, du lịch, chăm sóc sức khỏe,...

5. Phương pháp tổ hợp (Ensemble-Based Recommendation):

Sử dụng nhiều thuật toán hoặc mô hình gợi ý khác nhau và kết hợp kết quả lại để tạo ra gợi ý cuối cùng. Có thể kết hợp theo cách voting, trọng số hoặc xếp hạng trung bình. Mục tiêu là tận dụng ưu điểm và giảm thiểu hạn chế của từng mô hình riêng lẻ.

6. Phương pháp lai (Hybrid Recommendation):

Kết hợp nhiều chiến lược (ví dụ: lọc cộng tác và lọc nội dung, hoặc cộng tác và tri thức), giúp nâng cao hiệu quả tư vấn và giải quyết các vấn đề phổ biến như cold-start, dữ liệu thưa hoặc thiếu tính cá nhân hóa. Các kỹ thuật kết hợp có thể là:



Hình 2.2: Ví dụ lọc dựa trên nội dung

Nguồn: Viblo, 2024

- (a) **Kết hợp tuần tự (cascade),**
- (b) **Kết hợp song song (parallel),**
- (c) **Kết hợp mô hình hóa chung (feature-level hybrid).**

Đề xuất phổ biến (Popularity-Based Recommendation): Gợi ý những sản phẩm được ưa chuộng, có lượt xem/mua nhiều nhất. Phương pháp này phù hợp cho người dùng mới hoặc khi chưa có thông tin tương tác.

Việc lựa chọn phương pháp phù hợp phụ thuộc vào **loại dữ liệu hiện có, đặc điểm của người dùng và bài toán cụ thể**. Trong khuôn khổ đề tài này, nhóm lựa chọn phương pháp **lọc dựa trên nội dung kết hợp với đề xuất phổ biến** để xây dựng hệ thống tư vấn sản phẩm sữa rửa mặt – một lĩnh vực có yêu cầu cao về cá nhân hóa và hiểu rõ đặc điểm của từng người dùng.

2.1.2 Một số thách thức khi triển khai hệ thống khuyến nghị

Vấn đề “cold start” trong Recommendation System

Vấn đề “cold start” xuất phát khi hệ thống cần đưa ra đề xuất cho người dùng mới hoặc mục mới mà không có đủ dữ liệu lịch sử để dựa vào. Trong trường hợp này, mô hình truyền thống dựa trên dữ liệu lịch sử sẽ gặp khó khăn. Một số giải pháp bao gồm sử dụng Content-Based Recommendation System để đề xuất dựa trên thông tin chi tiết về nội dung hoặc sử dụng các chiến lược đặc biệt như đề xuất các mục phổ biến nhất cho người dùng mới.

Xử lý đánh giá thưa thớt (Sparse Data)

Sparse Data là tình trạng khi có ít thông tin hoặc đánh giá trên một phần lớn của ma trận đánh giá. Điều này gây khó khăn trong việc đo lường sự tương đồng giữa người dùng hoặc mục, đặc biệt là trong Collaborative Filtering. Một số giải pháp bao gồm sử dụng kỹ thuật lấp đầy (imputation) để dự đoán các giá trị còn thiếu, hoặc sử dụng các mô hình thống kê phức tạp để xử lý tốt trong trường hợp dữ liệu thưa thớt.

Privacy và vấn đề an ninh trong việc thu thập dữ liệu

Vấn đề về quyền riêng tư và an ninh là một thách thức lớn khi thu thập dữ liệu cho Recommendation System. Việc sử dụng thông tin cá nhân của người dùng đôi khi có thể gây lo ngại về quyền riêng tư. Một giải pháp tiếp cận là sử dụng kỹ thuật không giảm chất lượng (differential privacy) để bảo vệ thông tin cá nhân của người dùng trong quá trình thu thập dữ liệu. Đồng thời, việc thông báo rõ ràng và thu được sự đồng ý của người dùng cũng là quan trọng để đảm bảo tính minh bạch và đạo đức trong việc sử dụng dữ liệu.

Những thách thức này đặt ra những yêu cầu cao cho các nhà phát triển hệ thống khuyến nghị, đặc biệt là khi quy mô dữ liệu và độ phức tạp của mô hình tăng lên. Việc kết hợp các giải pháp kỹ thuật và chính sách có thể giúp tối ưu hóa hiệu suất của Recommendation System mà vẫn giữ cho quyền riêng tư và an ninh dữ liệu là ưu tiên hàng đầu.

2.2 Lọc dựa trên nội dung (Content-Based Filtering)

Lọc dựa trên nội dung (Content-Based Filtering) là một phương pháp phổ biến trong hệ thống tư vấn, hoạt động dựa trên việc phân tích **các đặc trưng mô tả sản phẩm** và **hồ sơ sở thích cá nhân của người dùng**. Thay vì dựa vào hành vi của cộng đồng, hệ thống sẽ dựa vào các thuộc tính cụ thể của sản phẩm mà người dùng đã từng quan tâm để đưa ra các gợi ý tương tự.

2.2.1 Cách tiếp cận tổng quát

Với phương pháp này, mỗi sản phẩm được biểu diễn bằng một vector đặc trưng (feature vector), bao gồm các thông tin như thể loại, thương hiệu, thành phần, mô tả,... Hồ sơ người dùng (user profile) được xây dựng bằng cách tổng hợp các đặc trưng của các sản phẩm mà họ đã tương tác tích cực (ví dụ như đã xem nhiều lần, thêm vào giỏ hàng, hoặc đã mua). Hệ thống sau đó sử dụng một **hàm đo độ tương đồng** – chẳng hạn như **cosine similarity** – để so sánh giữa hồ sơ người dùng và các sản phẩm khác, từ đó đưa ra danh sách gợi ý có mức tương đồng cao nhất.

2.2.2 Ứng dụng với tập dữ liệu ViEcomRec

Trong đề tài này, nhóm sử dụng tập dữ liệu **ViEcomRec** [4], được công bố trong bài báo “*ViEcomRec: A Dataset for Recommendation in Vietnamese E-Commerce*”, làm nguồn dữ liệu chính để triển khai phương pháp lọc dựa trên nội dung.

Từ tập dữ liệu ViEcomRec, nhóm tiến hành:

- **Lọc chọn sản phẩm sữa rửa mặt:** Sử dụng từ khóa hoặc nhãn phân loại sản phẩm (category) để trích xuất các mục sản phẩm liên quan đến sữa rửa mặt.
- **Trích xuất đặc trưng sản phẩm:** Các đặc trưng như tên sản phẩm (name), thương hiệu (brand), loại sản phẩm (type), mô tả sản phẩm (description) được xử lý và chuyển

thành vector nội dung. Nhóm áp dụng các kỹ thuật như **TF-IDF** để biến đổi các trường văn bản thành dạng vector có thể tính toán được ngoài ra còn thử nghiệm với một số mô hình nhúng văn bản thành vector embedding.

- **Xây dựng hồ sơ người dùng:** Dựa trên lịch sử tương tác của người dùng trong tập interactions (dựa vào thời gian comment sản phẩm đánh giá), nhóm xây dựng hồ sơ người dùng bằng cách tổng hợp nội dung các sản phẩm mà họ đã quan tâm.

Tính độ tương đồng: Để đưa ra gợi ý, nhóm sử dụng độ đo **cosine similarity** giữa hồ sơ người dùng và các sản phẩm sữa rửa mặt còn lại trong tập dữ liệu.

2.2.3 Ưu điểm và hạn chế

Ưu điểm:

- Phù hợp với bài toán có dữ liệu mô tả sản phẩm chi tiết như ViEcomRec.
- Có khả năng đưa ra gợi ý mang tính cá nhân hóa cao.
- Hoạt động tốt cả trong trường hợp người dùng mới, miễn là có thể nhập thông tin hoặc chọn sản phẩm mẫu.

Hạn chế:

- Hạn chế trong khả năng khám phá sản phẩm mới có đặc điểm khác biệt với lịch sử người dùng (vấn đề "thiếu khám phá").
- Phụ thuộc vào chất lượng và độ đầy đủ của các thuộc tính mô tả sản phẩm.
- Dễ bị "quá khớp"(overspecialization): chỉ gợi ý những sản phẩm rất giống nhau.

2.2.4 Kết luận

Lọc dựa trên nội dung là phương pháp phù hợp cho bài toán gợi ý sản phẩm sữa rửa mặt trong thương mại điện tử, nơi mà các đặc điểm như loại da, công dụng và thương hiệu đóng vai trò then chốt trong quyết định mua hàng. Việc tận dụng tập dữ liệu ViEcomRec giúp đảm bảo mô hình hoạt động trên dữ liệu thực tế, phù hợp với ngữ cảnh người dùng Việt Nam, từ đó nâng cao giá trị ứng dụng của hệ thống tư vấn.

2.3 Lọc cộng tác (Collaborative Filtering)

Lọc cộng tác (Collaborative Filtering - CF) là một trong những kỹ thuật phổ biến và mạnh mẽ nhất trong lĩnh vực hệ thống gợi ý. Thay vì dựa vào nội dung của các mục, CF tận dụng hành vi và sở thích của một cộng đồng người dùng để đưa ra dự đoán hoặc gợi ý cho một người dùng cụ thể.

2.3.1 Giới thiệu và các Thách thức chung của Lọc Cộng tác

Định nghĩa và Giả định cốt lõi Lọc cộng tác hoạt động dựa trên nguyên lý rằng nếu người dùng A có cùng sở thích với người dùng B về một số mục trong quá khứ, thì có khả năng cao họ sẽ có cùng sở thích về các mục khác trong tương lai. Tương tự, nếu mục X thường được thích bởi những người dùng cũng thích mục Y, thì một người dùng thích mục X cũng có thể sẽ thích mục Y. Giả định cốt lõi này thường được phát biểu là: *"Những người dùng có hành vi tương đồng trong quá khứ sẽ có hành vi tương đồng trong tương lai"* hoặc *"Những mục được đánh giá tương tự bởi cùng nhóm người dùng có khả năng là tương tự nhau"*.

Các thuộc tính của Ma trận Đánh giá Trước khi đi sâu vào các kỹ thuật CF, việc hiểu rõ bản chất của dữ liệu đầu vào là rất quan trọng. Dữ liệu tương tác người dùng-mục thường được biểu diễn dưới dạng một ma trận đánh giá (ratings matrix) R , trong đó mỗi hàng đại diện cho một người dùng, mỗi cột đại diện cho một mục, và giá trị R_{ui} là đánh giá của người dùng u cho mục i . Các loại đánh giá có thể bao gồm:

- **Đánh giá tường minh (Explicit Feedback):** Người dùng trực tiếp cung cấp đánh giá, ví dụ như xếp hạng từ 1 đến 5 sao cho một bộ phim, hoặc "thích"/"không thích" một sản phẩm.
- **Đánh giá ngầm định (Implicit Feedback):** Sở thích của người dùng được suy ra từ hành vi của họ, ví dụ như số lượt xem một video, số lần mua một sản phẩm, thời gian duyệt một trang web. Dữ liệu ngầm định thường phổ biến hơn nhưng cũng nhiều hơn và khó diễn giải hơn so với dữ liệu tường minh.
- **Đánh giá nhị phân (Binary Feedback):** Chỉ có hai giá trị, ví dụ như "đã mua"(1) hoặc "chưa mua"(0), "thích"(1) hoặc "không thích"(-1 hoặc 0).
- **Đánh giá theo khoảng (Interval-based Feedback):** Đánh giá nằm trong một khoảng giá trị cụ thể, ví dụ thang điểm 1-5, 1-10.
- **Đánh giá đơn nhất (Unary Feedback):** Chỉ ghi nhận các tương tác tích cực, ví dụ như lượt click, lượt mua. Không có thông tin về việc người dùng không thích một mục.

Loại dữ liệu đánh giá sẽ ảnh hưởng đến việc lựa chọn thuật toán CF và cách xử lý dữ liệu.

Thách thức chính Mặc dù mạnh mẽ, các phương pháp CF phải đối mặt với một số thách thức đáng kể:

- **Data Sparsity (Độ thưa của dữ liệu):** Đây là vấn đề lớn nhất và phổ biến nhất. Trong thực tế, ma trận tương tác người dùng-mục thường rất thưa, nghĩa là mỗi người dùng chỉ tương tác với một phần rất nhỏ trong tổng số các mục hiện có. Ví dụ, trên một trang thương mại điện tử có hàng triệu sản phẩm, một người dùng chỉ mua hoặc xem vài chục hoặc vài trăm sản phẩm. Độ thưa cao làm giảm hiệu quả của việc tìm kiếm những người dùng hoặc mục thực sự tương đồng, từ đó ảnh hưởng đến chất lượng gợi ý.
- **Cold Start (Khởi đầu lạnh):** Vấn đề này xảy ra trong hai trường hợp:

- *Người dùng mới (New User)*: Khi một người dùng mới đăng ký hệ thống, chưa có lịch sử tương tác nào. Hệ thống không có đủ thông tin để tìm ra những người dùng tương đồng hoặc xây dựng hồ sơ sở thích cho họ.
- *Mục mới (New Item)*: Khi một mục mới được thêm vào hệ thống, chưa có người dùng nào tương tác với nó. Hệ thống không thể gợi ý mục này cho đến khi có đủ dữ liệu tương tác.

Trong đồ án này, một giải pháp tiềm năng cho vấn đề cold start là sử dụng *Đề xuất dựa trên độ phổ biến* (đề cập ở Mục ??) như một phương án dự phòng hoặc khởi tạo.

- **Scalability (Khả năng mở rộng)**: Với số lượng người dùng và mục ngày càng tăng (có thể lên đến hàng triệu hoặc hàng tỷ), việc tính toán độ tương đồng giữa tất cả các cặp người dùng (trong User-Based CF) hoặc tất cả các cặp mục (trong Item-Based CF) trở nên rất tốn kém về mặt tính toán và tài nguyên. Điều này đặc biệt đúng với các phương pháp dựa trên láng giềng (Neighborhood-Based CF).
- **Synonymy (Từ đồng nghĩa)**: Hai mục có thể giống hệt nhau về bản chất nhưng lại có tên hoặc mã định danh khác nhau, khiến hệ thống coi chúng là hai mục riêng biệt. Điều này làm giảm khả năng tìm thấy sự tương đồng.
- **Gray Sheep (Cừu xám)**: Những người dùng có sở thích quá độc đáo hoặc không nhất quán, khó có thể tìm thấy những người dùng tương đồng hoặc những mục phù hợp với họ.
- **Shilling Attacks (Tấn công Shilling)**: Những người dùng độc hại cố tình tạo ra các hồ sơ giả mạo hoặc đánh giá không trung thực để quảng bá hoặc hạ bệ một số mục nhất định, làm sai lệch kết quả gợi ý.

Phân loại chính Các thuật toán Lọc Cộng tác thường được chia thành hai nhóm chính:

1. **Lọc Cộng tác Dựa trên Láng giềng (Neighborhood-Based CF)**: Còn được gọi là Memory-Based CF. Các phương pháp này tính toán độ tương đồng giữa những người dùng hoặc giữa các mục và sử dụng thông tin từ những "láng giềng" gần nhất để đưa ra dự đoán.
2. **Lọc Cộng tác Dựa trên Mô hình (Model-Based CF)**: Các phương pháp này xây dựng một mô hình từ dữ liệu tương tác người dùng-mục để học các đặc trưng tiềm ẩn (latent features) hoặc các quy luật, sau đó sử dụng mô hình này để dự đoán.

Hai nhóm phương pháp này sẽ được trình bày chi tiết trong các mục tiếp theo.

2.3.2 Lọc Cộng tác Dựa trên Láng Giềng (Neighborhood-Based CF)

Giới thiệu Lọc Cộng tác Dựa trên Láng Giềng (Neighborhood-Based CF), hay còn gọi là Lọc Cộng tác Dựa trên Bộ nhớ (Memory-Based CF), là một trong những cách tiếp cận sớm nhất và trực quan nhất trong CF. Nguyên lý cơ bản của phương pháp này là "*những người*

dùng có cùng sở thích trong quá khứ sẽ có cùng sở thích trong tương lai" (đối với User-Based CF) hoặc "những mục được đánh giá tương tự bởi cùng một nhóm người dùng có khả năng là tương tự nhau" (đối với Item-Based CF). Thay vì học một mô hình phức tạp, các phương pháp này trực tiếp sử dụng toàn bộ (hoặc một phần) ma trận tương tác người dùng-mục để tìm ra các "láng giềng"(neighbors) – những người dùng hoặc mục tương đồng – và dựa vào đánh giá của các láng giềng này để đưa ra dự đoán cho người dùng mục tiêu.

Mô hình Lọc Cộng tác User-Based (User-Based CF) Trong User-Based CF, để dự đoán đánh giá của người dùng u cho mục i (mà u chưa tương tác), hệ thống sẽ tìm một tập hợp những người dùng N_u có sở thích tương đồng nhất với u (gọi là láng giềng của u) và đã từng đánh giá mục i . Dự đoán sau đó được tính dựa trên đánh giá của những người dùng này cho mục i .

Xác định láng giềng (Neighbor Selection)

- **Đo độ tương đồng giữa người dùng:** Để tìm ra những người dùng tương đồng, chúng ta cần một độ đo tương đồng. Các độ đo phổ biến bao gồm:

- *Pearson Correlation Coefficient (Hệ số tương quan Pearson):* Đo lường mức độ tương quan tuyến tính giữa vector đánh giá của hai người dùng. Công thức được trình bày trong Mục ?? (giả sử bạn có mục 2.6 nói về độ đo tương đồng). Hệ số này nằm trong khoảng $[-1, 1]$.

$$sim(u, v) = \frac{\sum_{i \in I_{uv}} (R_{ui} - \bar{R}_u)(R_{vi} - \bar{R}_v)}{\sqrt{\sum_{i \in I_{uv}} (R_{ui} - \bar{R}_u)^2} \sqrt{\sum_{i \in I_{uv}} (R_{vi} - \bar{R}_v)^2}} \quad (2.1)$$

trong đó I_{uv} là tập các mục mà cả người dùng u và v đều đã đánh giá, $\bar{R}_u$ và $\bar{R}_v$ là đánh giá trung bình của người dùng u và v .

- *Cosine Similarity (Độ tương đồng Cosine):* Đo lường cosin của góc giữa hai vector đánh giá. Có thể tính trên dữ liệu gốc (Raw Cosine) hoặc dữ liệu đã trừ trung bình (Mean-centered Cosine). Công thức cũng được đề cập trong Mục ??.

$$sim(u, v) = \frac{\vec{R}_u \cdot \vec{R}_v}{\|\vec{R}_u\| \cdot \|\vec{R}_v\|} = \frac{\sum_{i \in I_{uv}} R_{ui} R_{vi}}{\sqrt{\sum_{i \in I_{uv}} R_{ui}^2} \sqrt{\sum_{i \in I_{uv}} R_{vi}^2}} \quad (2.2)$$

Khi sử dụng Mean-centered Cosine, R_{ui} được thay thế bằng $R_{ui} - \bar{R}_u$.

- *Jaccard Similarity (Độ tương đồng Jaccard):* Thường được sử dụng cho dữ liệu ngầm định hoặc nhị phân, đo lường tỷ lệ giữa số mục chung mà hai người dùng cùng tương tác và tổng số mục mà ít nhất một trong hai người dùng đã tương tác.

$$sim(u, v) = \frac{|I_u \cap I_v|}{|I_u \cup I_v|} \quad (2.3)$$

trong đó I_u là tập các mục người dùng u đã tương tác.

- **Cách chọn Top-N láng giềng:** Sau khi tính toán độ tương đồng giữa người dùng mục tiêu u và tất cả các người dùng khác, hệ thống sẽ chọn ra N người dùng có độ tương đồng cao nhất làm láng giềng. Giá trị N là một siêu tham số cần được điều chỉnh.

Hàm dự đoán (Prediction Function) Sau khi xác định được tập láng giềng N_u của người dùng u (những người đã đánh giá mục i), đánh giá dự đoán $\hat{R}_{ui}$ của người dùng u cho mục i có thể được tính bằng một số cách:

- *Trung bình có trọng số (Weighted Average):*

$$\hat{R}_{ui} = \frac{\sum_{v \in N_u(i)} \text{sim}(u, v) \cdot R_{vi}}{\sum_{v \in N_u(i)} |\text{sim}(u, v)|} \quad (2.4)$$

trong đó $N_u(i)$ là tập láng giềng của u đã đánh giá mục i .

- *Dự đoán dựa trên độ lệch so với trung bình (Mean-centered Prediction):* Để giải quyết vấn đề một số người dùng có xu hướng đánh giá cao hơn hoặc thấp hơn người khác, có thể sử dụng công thức:

$$\hat{R}_{ui} = \bar{R}_u + \frac{\sum_{v \in N_u(i)} \text{sim}(u, v) \cdot (R_{vi} - \bar{R}_v)}{\sum_{v \in N_u(i)} |\text{sim}(u, v)|} \quad (2.5)$$

Mô hình Lọc Cộng tác Item-Based (Item-Based CF) Trong Item-Based CF, để dự đoán đánh giá của người dùng u cho mục i , hệ thống sẽ tìm một tập hợp những mục N_i tương đồng nhất với mục i (láng giềng của i) mà người dùng u đã từng đánh giá. Dự đoán sau đó được tính dựa trên đánh giá của người dùng u cho những mục tương đồng này.

Xác định láng giềng item

- **Đo độ tương đồng giữa các mục:**

- *Adjusted Cosine Similarity (Độ tương đồng Cosine Điều chỉnh):* Đây là một phương pháp phổ biến cho Item-Based CF. Thay vì tính Cosine trực tiếp trên vector đánh giá của các mục (vector cột trong ma trận R), Adjusted Cosine trừ đi đánh giá trung bình của từng người dùng trước khi tính toán. Điều này giúp chuẩn hóa sự khác biệt trong thang đánh giá của các người dùng.

$$\text{sim}(i, j) = \frac{\sum_{u \in U_{ij}} (R_{ui} - \bar{R}_u)(R_{uj} - \bar{R}_u)}{\sqrt{\sum_{u \in U_{ij}} (R_{ui} - \bar{R}_u)^2} \sqrt{\sum_{u \in U_{ij}} (R_{uj} - \bar{R}_u)^2}} \quad (2.6)$$

trong đó U_{ij} là tập những người dùng đã đánh giá cả mục i và mục j .

- **Cách chọn Top-N láng giềng item:** Tương tự User-Based CF, chọn N mục tương đồng nhất.

Hàm dự đoán (Prediction Function) Đánh giá dự đoán $\hat{R}_{ui}$ của người dùng u cho mục i được tính bằng:

$$\hat{R}_{ui} = \frac{\sum_{j \in N_i(u)} \text{sim}(i, j) \cdot R_{uj}}{\sum_{j \in N_i(u)} |\text{sim}(i, j)|} \quad (2.7)$$

trong đó $N_i(u)$ là tập láng giềng của mục i (những mục tương đồng với i) mà người dùng u đã đánh giá.

Các cải tiến và yếu tố ảnh hưởng

- **Significance Weighting / Discounted Similarity:** Khi hai người dùng (hoặc hai mục) chỉ có một số lượng rất nhỏ các mục (hoặc người dùng) đánh giá chung, độ tương đồng tính được có thể không đáng tin cậy. Để giải quyết vấn đề này, có thể áp dụng trọng số giảm (discount factor) cho độ tương đồng. Ví dụ, nhân độ tương đồng với một hệ số $\frac{|I_{uv}|}{\beta}$ hoặc $\min(1, \frac{|I_{uv}|}{\beta})$, trong đó $|I_{uv}|$ là số lượng mục đánh giá chung và β là một ngưỡng (ví dụ: 50).
- **Inverse User Frequency (IUF) / Inverse Item Frequency (IIF):** Trong Item-Based CF, một số người dùng có thể đánh giá rất nhiều mục, và sự tương đồng dựa trên những người dùng này có thể bị ảnh hưởng. IUF có thể được sử dụng để giảm trọng số của những người dùng "quá năng động". Tương tự, trong User-Based CF, một số mục rất phổ biến (ví dụ, phim bom tấn) có thể được nhiều người cùng thích/không thích, làm tăng giả tạo độ tương đồng giữa họ. IIF có thể được dùng để giảm trọng số của những mục này, tương tự như IDF trong truy vấn thông tin, giúp làm nổi bật các sở thích đặc trưng hơn.

Ưu điểm và Hạn chế của Neighborhood-Based CF

- **Ưu điểm:**
 - *Đơn giản và trực quan:* Dễ hiểu và dễ triển khai.
 - *Tính diễn giải cao (Interpretability):* Dễ dàng giải thích tại sao một mục được gợi ý (ví dụ: "Vì bạn thích mục A, và những người dùng khác cũng thích mục A thường thích mục B").
 - *Không cần huấn luyện mô hình phức tạp trước:* Dữ liệu được sử dụng trực tiếp.
 - *Có thể cập nhật tương đối nhanh khi có đánh giá mới* (mặc dù việc tính lại toàn bộ độ tương đồng có thể tốn kém).
- **Hạn chế:**
 - *Data Sparsity:* Hiệu suất giảm mạnh khi dữ liệu thưa.
 - *Scalability:* Tính toán độ tương đồng cho hàng triệu người dùng/mục là rất tốn kém.
 - *Cold Start:* Khó khăn với người dùng mới và mục mới.
 - *Chất lượng gợi ý có thể không cao bằng Model-Based CF* trong nhiều trường hợp.

Độ phức tạp tính toán

- **User-Based CF:**
 - Tính toán độ tương đồng giữa tất cả các cặp người dùng: $O(M^2 \cdot I_{avg})$, trong đó M là số người dùng, I_{avg} là số mục trung bình một người dùng đánh giá.

- Dự đoán: $O(N \cdot K)$, với N là số mục cần dự đoán, K là số láng giềng.
- **Item-Based CF:**
 - Tính toán độ tương đồng giữa tất cả các cặp mục: $O(I^2 \cdot M_{avg})$, trong đó I là số mục, M_{avg} là số người dùng trung bình đánh giá một mục.
 - Dự đoán: $O(M \cdot K')$, với M là số người dùng cần dự đoán, K' là số láng giềng item.

Trong thực tế, số lượng mục thường ít hơn số lượng người dùng, nên Item-Based CF thường có khả năng mở rộng tốt hơn về mặt xây dựng ma trận tương đồng offline.

So sánh User-Based và Item-Based CF

- **Tính ổn định của láng giềng:** Sở thích của người dùng có thể thay đổi nhanh chóng, trong khi sự tương đồng giữa các mục thường ổn định hơn theo thời gian. Do đó, ma trận tương đồng item-item trong Item-Based CF ít cần cập nhật thường xuyên hơn so với ma trận user-user.
- **Khả năng mở rộng:** Như đã đề cập, Item-Based CF thường có lợi thế hơn khi số lượng mục nhỏ hơn số lượng người dùng.
- **Tính diễn giải:** Cả hai đều có tính diễn giải tốt. Gợi ý User-Based: "Những người giống bạn cũng thích...". Gợi ý Item-Based: "Vì bạn thích mục này, bạn có thể cũng thích những mục tương tự...".
- **Độ thưa của dữ liệu:** Cả hai đều bị ảnh hưởng, nhưng Item-Based có thể hoạt động tốt hơn một chút khi mỗi mục có nhiều đánh giá hơn là mỗi người dùng đánh giá nhiều mục.
- **Xử lý item mới/user mới:** User-Based gặp khó khăn với user mới. Item-Based gặp khó khăn với item mới.

Trong nhiều ứng dụng thực tế, Item-Based CF thường được ưa chuộng hơn do tính ổn định và khả năng mở rộng tốt hơn khi số lượng item < số lượng user (ví dụ: Amazon).

Lọc Cộng tác Dựa trên Mô hình (Model-Based CF)

Giới thiệu Khác với các phương pháp dựa trên láng giềng (Neighborhood-Based CF) sử dụng trực tiếp toàn bộ ma trận tương tác, Lọc Cộng tác Dựa trên Mô hình (Model-Based CF) tập trung vào việc xây dựng một mô hình (model) nhỏ gọn từ dữ liệu huấn luyện. Mô hình này cố gắng học các quy luật, các mẫu hành vi hoặc các đặc trưng tiềm ẩn (latent features) trong dữ liệu tương tác người dùng-mục. Sau khi mô hình được huấn luyện, nó sẽ được sử dụng để dự đoán các đánh giá còn thiếu hoặc để gợi ý các mục cho người dùng.

So với Neighborhood-Based CF, Model-Based CF thường có lợi thế về khả năng xử lý dữ liệu thưa tốt hơn, khả năng mở rộng cao hơn (sau khi mô hình đã được huấn luyện, việc dự đoán thường nhanh hơn), và đôi khi mang lại độ chính xác cao hơn.

Ưu điểm của Model-Based CF

- **Khả năng xử lý dữ liệu thưa tốt hơn:** Nhiều kỹ thuật Model-Based, đặc biệt là Phân rã Ma trận, có khả năng khái quát hóa từ dữ liệu thưa và dự đoán tốt hơn cho các tương tác chưa biết.
- **Khả năng mở rộng (Scalability):** Việc huấn luyện mô hình có thể tốn thời gian (offline), nhưng sau khi mô hình được xây dựng, việc đưa ra dự đoán (online) thường rất nhanh, không phụ thuộc trực tiếp vào số lượng người dùng hay mục như Neighborhood-Based.
- **Tốc độ dự đoán nhanh hơn:** Sau khi mô hình được huấn luyện, việc tính toán dự đoán thường chỉ là các phép toán đơn giản trên mô hình đã học.
- **Tránh Overfitting:** Các kỹ thuật như Regularization giúp mô hình không bị quá khớp (overfit) với dữ liệu huấn luyện, từ đó khái quát hóa tốt hơn cho dữ liệu mới.
- **Kích thước mô hình nhỏ gọn (Space-efficiency):** Mô hình đã học thường có kích thước nhỏ hơn nhiều so với ma trận tương tác gốc, giúp tiết kiệm không gian lưu trữ.

Kỹ thuật Phân rã Ma trận (Matrix Factorization - MF) Phân rã Ma trận là một trong những kỹ thuật Model-Based CF hiệu quả và phổ biến nhất. Ý tưởng cốt lõi là biểu diễn cả người dùng và mục trong một không gian đặc trưng tiềm ẩn (latent feature space) có số chiều thấp hơn.

Nguyên lý cơ bản Giả sử chúng ta có ma trận đánh giá R kích thước $M \times I$ (M người dùng, I mục). Mục tiêu của MF là tìm hai ma trận có số chiều thấp hơn, P (ma trận đặc trưng người dùng) kích thước $M \times K$ và Q (ma trận đặc trưng mục) kích thước $I \times K$, sao cho tích của chúng xấp xỉ ma trận R :

$$R \approx P \cdot Q^T \quad (2.8)$$

Trong đó, K là số chiều của không gian tiềm ẩn (số đặc trưng tiềm ẩn), thường nhỏ hơn nhiều so với M và I . Mỗi hàng p_u của ma trận P là một vector K -chiều biểu diễn người dùng u , và mỗi hàng q_i của ma trận Q (tương ứng cột q_i của Q^T) là một vector K -chiều biểu diễn mục i . Đánh giá dự đoán $\hat{R}_{ui}$ của người dùng u cho mục i được tính bằng tích vô hướng của vector đặc trưng của người dùng u và vector đặc trưng của mục i :

$$\hat{R}_{ui} = p_u \cdot q_i^T = \sum_{k=1}^K p_{uk} \cdot q_{ik} \quad (2.9)$$

Các đặc trưng tiềm ẩn này có thể được hiểu ngầm là các khía cạnh mà người dùng quan tâm hoặc các thuộc tính của mục (ví dụ: thể loại phim, diễn viên, đạo diễn đối với gợi ý phim; hoặc các đặc trưng trừu tượng hơn mà mô hình tự học được).

Hàm mục tiêu (Loss Function) Để tìm ra các ma trận P và Q , chúng ta cần tối thiểu hóa một hàm lỗi (loss function) đo lường sự khác biệt giữa đánh giá thực tế và đánh giá dự đoán trên tập các đánh giá đã biết (observed ratings). Một hàm lỗi phổ biến là tổng bình phương lỗi (Sum of Squared Errors - SSE) hoặc Root Mean Squared Error (RMSE):

$$\min_{P, Q} \sum_{(u, i) \in S_{obs}} (R_{ui} - p_u \cdot q_i^T)^2 \quad (2.10)$$

trong đó S_{obs} là tập hợp các cặp (u, i) mà R_{ui} đã được quan sát.

Các phương pháp tối ưu

- **Stochastic Gradient Descent (SGD):** SGD là một phương pháp lặp để tối ưu hóa hàm mục tiêu. Với mỗi đánh giá quan sát R_{ui} trong tập huấn luyện, các vector p_u và q_i được cập nhật theo hướng ngược lại của gradient của thành phần lỗi tương ứng:

$$e_{ui} = R_{ui} - p_u \cdot q_i^T \quad (2.11)$$

$$p_u \leftarrow p_u + \gamma \cdot (e_{ui} \cdot q_i - \lambda \cdot p_u) \quad (2.12)$$

$$q_i \leftarrow q_i + \gamma \cdot (e_{ui} \cdot p_u - \lambda \cdot q_i) \quad (2.13)$$

trong đó γ là tốc độ học (learning rate) và λ là tham số điều chuẩn (regularization parameter). SGD lặp qua tất cả các đánh giá đã biết nhiều lần (epochs) cho đến khi hội tụ.

- **Ưu điểm:** Dễ triển khai, hiệu quả cho tập dữ liệu lớn và thưa, có thể dễ dàng kết hợp các loại điều chuẩn.
- **Nhược điểm:** Cần chọn learning rate phù hợp, có thể bị kẹt ở cực tiểu địa phương (mặc dù trong thực tế thường cho kết quả tốt), quá trình hội tụ có thể nhiều.
- **Alternating Least Squares (ALS):** ALS là một phương pháp tối ưu khác. Thay vì cập nhật P và Q đồng thời, ALS cố định một ma trận và tối ưu ma trận còn lại, sau đó lặp lại quá trình này. Ví dụ, khi cố định Q , hàm mục tiêu (2.10) trở thành một bài toán bình phương tối thiểu (least squares) đối với P , và ngược lại. ALS đặc biệt hiệu quả cho việc song song hóa và xử lý dữ liệu ngầm định (implicit feedback).

Regularization (Điều chuẩn) Để tránh overfitting, đặc biệt khi dữ liệu thưa, một thành phần điều chuẩn thường được thêm vào hàm mục tiêu. Điều chuẩn L2 (L2 norm regularization, hay Tikhonov regularization) là phổ biến nhất:

$$\min_{P, Q} \sum_{(u, i) \in S_{obs}} (R_{ui} - p_u \cdot q_i^T)^2 + \lambda (||P||_F^2 + ||Q||_F^2) \quad (2.14)$$

trong đó $||P||_F^2 = \sum_u ||p_u||^2 = \sum_u \sum_k p_{uk}^2$ là Frobenius norm của ma trận P , và λ là tham số điều chuẩn kiểm soát mức độ "phạt" các giá trị lớn trong P và Q .

Kết hợp Độ Lệch (Biases) Đánh giá của người dùng thường bị ảnh hưởng bởi các yếu tố không liên quan trực tiếp đến tương tác giữa đặc trưng tiềm ẩn của người dùng và mục. Ví dụ:

- *Độ lệch toàn cục (Global Average - μ)*: Đánh giá trung bình của tất cả các đánh giá.
- *Độ lệch người dùng (User Bias - b_u)*: Một số người dùng có xu hướng đánh giá cao hơn (hoặc thấp hơn) so với mức trung bình.
- *Độ lệch mục (Item Bias - b_i)*: Một số mục có xu hướng được đánh giá cao hơn (hoặc thấp hơn) so với mức trung bình, bất kể người dùng là ai.

Kết hợp các độ lệch này vào mô hình dự đoán có thể cải thiện đáng kể độ chính xác:

$$\hat{R}_{ui} = \mu + b_u + b_i + p_u \cdot q_i^T \quad (2.15)$$

Hàm mục tiêu cũng được điều chỉnh tương ứng để học các tham số b_u và b_i cùng với P và Q .

Các mô hình MF cụ thể

- **Basic MF / SVD-inspired (FunkSVD)**: Đây là mô hình MF cơ bản thường được tối ưu bằng SGD, kết hợp regularization và biases như đã mô tả ở trên. Mặc dù tên gọi có "SVD", nó không thực hiện phân rã SVD đầy đủ theo nghĩa toán học mà là một kỹ thuật MF được phổ biến bởi Simon Funk trong cuộc thi Netflix Prize.
- **(Optional) Singular Value Decomposition (SVD)**: Nếu giải thích SVD đúng nghĩa, cần đề cập đến việc nó là một kỹ thuật phân rã ma trận chính xác cho ma trận đầy đủ. Với ma trận thưa, Truncated SVD thường được áp dụng sau khi điền các giá trị thiếu (ví dụ, bằng trung bình). Các slide SVD của bạn (*Matrix Factorization with Regularization*) cung cấp cái nhìn sâu về SVD và cách xử lý dữ liệu thưa thông qua phương pháp lặp.
- **(Optional) Non-negative Matrix Factorization (NMF)**: Khi các đánh giá là không âm (ví dụ, số lượt xem, số lượt mua), NMF ràng buộc các ma trận P và Q cũng phải không âm. Điều này có thể mang lại các đặc trưng tiềm ẩn dễ diễn giải hơn (ví dụ: "mức độ người dùng thích thể loại phim hành động"). Các slide của bạn về NMF (*Matrix Factorization with Regularization*) đã trình bày rất tốt về mục tiêu, quy tắc cập nhật và tính diễn giải.

(Optional) Incremental Latent Component Training Thay vì tối ưu tất cả K thành phần tiềm ẩn cùng một lúc, phương pháp này huấn luyện từng thành phần một cách tuần tự. Sau khi huấn luyện xong một thành phần, lỗi còn lại (residual) sẽ được sử dụng làm mục tiêu cho việc huấn luyện thành phần tiếp theo. Điều này có thể giúp hội tụ nhanh hơn và ổn định hơn.

(Optional) Các Mô hình Model-Based CF khác Nếu phạm vi đề án cho phép, có thể xem xét hoặc đề cập đến các mô hình sau:

- **Lọc Cộng tác Dựa trên Luật (Rule-Based CF - Association Rules):** Tìm các luật dạng "Nếu người dùng mua Sữa, Bánh mì thì cũng có khả năng mua Bơ". Yêu cầu dữ liệu giao dịch (thường là implicit, binary).
- **Lọc Cộng tác Naive Bayes:** Áp dụng mô hình xác suất Naive Bayes để dự đoán khả năng người dùng thích một mục dựa trên các mục khác họ đã đánh giá.
- **Mô hình dựa trên Mạng Neural (Neural Collaborative Filtering - NCF):** Sử dụng các kiến trúc mạng neural (ví dụ: Multi-Layer Perceptron - MLP, Autoencoders) để học các tương tác phi tuyến phức tạp giữa người dùng và mục, hoặc để học các biểu diễn nhúng (embeddings) tốt hơn cho người dùng và mục. Đây là một hướng phát triển rất mạnh mẽ hiện nay.

Ứng dụng Lọc Cộng tác với tập dữ liệu ViEcomRec

Trong khuôn khổ đề án này, các phương pháp Lọc Cộng tác sẽ được áp dụng trên tập dữ liệu ViEcomRec.

- **Lựa chọn phương pháp CF:** Dựa trên đặc điểm của ViEcomRec (ví dụ: độ thưa, loại dữ liệu đánh giá là explicit hay implicit, quy mô dữ liệu), một hoặc nhiều phương pháp CF sẽ được lựa chọn để triển khai. Ví dụ:
 - Nếu ViEcomRec có dữ liệu đánh giá tường minh (ratings), có thể triển khai cả Neighborhood-Based CF (User-Based và Item-Based với Pearson/Adjusted Cosine) và Model-Based CF (ví dụ: Basic MF với SGD và biases).
 - Nếu ViEcomRec chủ yếu là dữ liệu ngầm định (lượt mua, lượt xem), các biến thể của MF như ALS hoặc các phương pháp phù hợp với implicit data (ví dụ: BPR - Bayesian Personalized Ranking, hoặc NCF cho implicit data) sẽ được cân nhắc. Jaccard Similarity cũng có thể được dùng cho Neighborhood-Based.

Việc triển khai nhiều phương pháp cho phép so sánh hiệu quả của chúng.

- **Xây dựng ma trận User-Item:** Dữ liệu tương tác từ ViEcomRec (ví dụ: trường 'rating' trong 'interactions.jsonl' nếu là đánh giá tường minh, hoặc tần suất mua hàng, lượt xem từ các log tương tác nếu là ngầm định) sẽ được sử dụng để xây dựng ma trận user-item. Cần xác định rõ cách định lượng các tương tác ngầm định nếu có.
- **Xử lý các thách thức cụ thể với ViEcomRec:**
 - *Độ thưa:* Phân tích mức độ thưa của ma trận user-item từ ViEcomRec. Các kỹ thuật Model-Based MF thường có khả năng xử lý tốt hơn.
 - *Cold Start:*
 - **User Cold Start:** Đối với người dùng mới trong ViEcomRec, hệ thống có thể mặc định gợi ý các sản phẩm phổ biến nhất (tham khảo Mục ??) hoặc các sản phẩm mới nổi bật.

- **Item Cold Start:** Đối với sản phẩm mới, Lộ Cộg tác thuần túy sẽ gặp khó khăn. Trong trường hợp này, hệ thống sử dụng là lai (hybrid) và có thành phần Content-Based (Mục ??), thì thông tin nội dung của sản phẩm mới có thể được sử dụng để đưa ra gợi ý ban đầu.
- **Mô tả triển khai chi tiết** sẽ được trình bày trong Chương ?? .

2.4 Đề xuất dựa trên độ phổ biến

Phương pháp **đề xuất dựa trên độ phổ biến (Popularity-Based Recommendation)** là một kỹ thuật cơ bản trong lĩnh vực hệ thống tư vấn, trong đó các sản phẩm được gợi ý cho người dùng dựa trên **mức độ phổ biến tổng thể** của chúng trong cộng đồng. Độ phổ biến thường được đo lường thông qua các hành vi tương tác như số lượt xem, số lượt thêm vào giỏ hàng, số lượt mua hoặc số lượt đánh giá của tất cả người dùng.

2.4.1 Nguyên lý hoạt động

Không giống như các phương pháp cá nhân hóa – vốn phụ thuộc vào hồ sơ người dùng hoặc lịch sử tương tác – đề xuất phổ biến sử dụng thống kê toàn cục để xác định những sản phẩm “hot” nhất trong hệ thống. Mô hình này giả định rằng các sản phẩm được nhiều người quan tâm thì cũng có khả năng phù hợp với người dùng mới hoặc người dùng không có lịch sử hành vi cụ thể.

Trong bối cảnh thực tế, phương pháp này thường được triển khai theo các bước sau:

1. Thống kê tần suất tương tác của từng sản phẩm (ví dụ: số lượt mua, lượt xem, lượt đánh giá).
2. Xếp hạng sản phẩm theo mức độ phổ biến từ cao đến thấp.
3. Lựa chọn danh sách top-K sản phẩm phổ biến nhất để đưa vào hệ thống gợi ý.

2.4.2 Ứng dụng với tập dữ liệu ViEcomRec

Để xây dựng mô hình đề xuất dựa trên độ phổ biến, nhóm thực hiện các bước sau:

- **Lọc dữ liệu sản phẩm:** Trích xuất tập con dữ liệu gồm các sản phẩm thuộc nhóm "sữa rửa mặt" thông qua trường phân loại category.
- **Thống kê hành vi:** Đếm tần suất các hành vi tương tác (click, thêm vào giỏ hàng, mua) của từng sản phẩm. Tùy vào mục tiêu đề xuất, nhóm có thể gán trọng số cao hơn cho các hành vi mang tính chuyển đổi (ví dụ: mua hàng có trọng số cao hơn lượt xem).
- **Xây dựng bảng xếp hạng:** Các sản phẩm sữa rửa mặt được sắp xếp theo tổng điểm phổ biến và cập nhật định kỳ để phản ánh thay đổi về xu hướng tiêu dùng.

- **Đề xuất mặc định:** Trong trường hợp hệ thống không thu thập được thông tin cá nhân từ người dùng (ví dụ: người dùng mới), danh sách sản phẩm phổ biến nhất sẽ được sử dụng làm gợi ý mặc định.

2.4.3 Đánh giá ưu điểm và hạn chế

Ưu điểm:

- **Dễ triển khai và hiệu quả tức thời:** Do không cần xây dựng hồ sơ người dùng hay vector hóa sản phẩm.
- **Giải quyết tốt bài toán cold-start ở phía người dùng:** Khi không có bất kỳ thông tin nào về người dùng, đây là một chiến lược khởi đầu hợp lý.
- **Phản ánh đúng xu hướng thị trường tại thời điểm thực tế.**

Hạn chế:

- **Thiếu tính cá nhân hóa:** Mọi người dùng đều nhận được gợi ý giống nhau, không phản ánh nhu cầu cụ thể.
- **Bị chi phối bởi sản phẩm được quảng cáo hoặc có hiệu ứng lan truyền:** Không đảm bảo chất lượng gợi ý về mặt nội dung.
- **Thiếu tính đa dạng và khám phá:** Hệ thống có xu hướng tập trung vào một số sản phẩm nhất định, làm giảm khả năng tiếp cận các sản phẩm ít phổ biến nhưng phù hợp.

2.4.4 Vai trò trong hệ thống tư vấn

Trong khuôn khổ đề tài, phương pháp đề xuất dựa trên độ phổ biến được sử dụng như một **thành phần khởi đầu quan trọng**, đặc biệt hữu ích đối với người dùng mới hoặc khi hệ thống chưa có đủ thông tin cá nhân hóa. Ngoài ra, danh sách sản phẩm phổ biến còn đóng vai trò như **nguồn dữ liệu đầu vào cho mô-đun lọc dựa trên nội dung**, nơi các sản phẩm phổ biến sẽ được sắp xếp lại theo mức độ tương đồng với đặc điểm cá nhân của người dùng (nếu có). Việc kết hợp hai phương pháp này giúp cân bằng giữa khả năng bao phủ rộng và độ chính xác trong gợi ý sản phẩm.

2.5 Phương pháp biểu diễn đặc trưng (Embedding Techniques)

Trong bài toán xây dựng hệ thống tư vấn sản phẩm, việc biểu diễn đặc trưng (**embedding**) của dữ liệu văn bản đóng vai trò quan trọng nhằm chuyển đổi thông tin mô tả sản phẩm (như tên sản phẩm, đánh giá của người dùng, thành phần, nguồn gốc) thành các vectơ số học để hệ thống có thể xử lý và tính toán. Dưới đây là một số phương pháp biểu diễn đặc trưng phổ biến được áp dụng trong các hệ thống gợi ý kết hợp lọc cộng tác và lọc dựa trên nội dung.

2.5.1 TF-IDF (Term Frequency – Inverse Document Frequency)

TF-IDF là một trong những phương pháp truyền thống và phổ biến nhất để chuyển đổi văn bản thành vector. Kỹ thuật này dựa trên tần suất xuất hiện của các từ trong một văn bản so với tần suất xuất hiện của từ đó trong toàn bộ tập dữ liệu, từ đó xác định mức độ quan trọng của từ trong ngữ cảnh cụ thể. Theo Robertson và Sparck Jones, TF-IDF được tính bằng công thức [5]:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t) \quad (2.16)$$

$$\text{TF}(t, d) = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (1)$$

$$\text{IDF}(t) = \log \left(\frac{N}{\text{df}_t} \right) \quad (2)$$

(1): tần suất từ trong tài liệu

(2): tần suất nghịch đảo của tài liệu

Trong đó:

- $f_{t,d}$: Số lần từ t xuất hiện trong tài liệu d .
- $\sum_{t' \in d} f_{t',d}$: Tổng số lần xuất hiện của tất cả các từ trong tài liệu d .
- N : Tổng số tài liệu trong tập dữ liệu.
- df_t : Số tài liệu có chứa từ t .

Trong đề tài này, TF-IDF được sử dụng để biểu diễn văn bản mô tả sản phẩm (description) trong tập dữ liệu ViEcomRec. Mỗi sản phẩm được xem như một “tài liệu”, và từ ngữ trong mô tả được chuyển thành vector theo trọng số TF-IDF [6]. Cách tiếp cận này có ưu điểm là đơn giản, hiệu quả với dữ liệu văn bản ngắn, đồng thời dễ tích hợp với các phương pháp đo độ tương đồng như cosine similarity.

TF-IDF vẫn có thể **"tích hợp vào tất cả các hệ thống truy xuất thông tin"** và tiếp tục là nền tảng cho nhiều công cụ tìm kiếm hiện đại [5]. Tuy nhiên, phương pháp này không thể nắm bắt được mối quan hệ ngữ nghĩa giữa các từ và bỏ qua ngữ cảnh trong việc xử lý các lần xuất hiện của từ vì vậy cũng cần nhắc khi cần mở rộng Hệ thống để kết hợp Truy xuất thông tin (**Information Retrieval**)

2.5.2 Word Embedding

Các mô hình Word Embedding như **Word2Vec** (Mikolov et al., 2013) [7] và **FastText** (Bojanowski et al., 2017) [8] biểu diễn từ ngữ dưới dạng các vectơ liên tục trong không

gian đa chiều, giúp nắm bắt ngữ nghĩa và quan hệ ngữ cảnh giữa các từ. Khác với TF-IDF, Word Embedding có khả năng hiểu được sự tương đồng ngữ nghĩa (ví dụ: "sữa rửa mặt" gần với "dầu tẩy trang" hơn là "kem dưỡng"). Các từ có ý nghĩa tương đồng sẽ được ánh xạ gần nhau trong không gian vector.

Nếu mô tả sản phẩm chứa các thông tin giàu ngữ nghĩa và có độ dài vừa phải, Word Embedding có thể giúp hệ thống hiểu sâu hơn về mối liên hệ giữa các đặc trưng. Tuy nhiên, phương pháp này yêu cầu dữ liệu huấn luyện lớn và chất lượng cao để đạt được hiệu quả tối ưu.

Word2Vec bao gồm hai kiến trúc chính [9]:

- **Continuous Bag of Words (CBOW):** Mô hình này "sử dụng từ từ lịch sử và tương lai đồng thời để phân loại chính xác từ ở giữa trong từ vựng". Nghiên cứu gần đây của Irsoy và cộng sự đã chỉ ra rằng "sau khi sửa lỗi trong cập nhật gradient CBOW, có thể học được word embeddings CBOW hoàn toàn cạnh tranh với Skip-gram"
- **Skip-gram:** Khác với CBOW, Skip-gram "cố gắng tối đa hóa việc phân loại một từ dựa trên từ khác trong cùng một câu". Mô hình này đặc biệt hiệu quả với các từ hiếm.

2.5.3 Sentence Embedding

Trong những năm gần đây, các mô hình học sâu như **BERT [10] (Bidirectional Encoder Representations from Transformers)**, BERT đã đạt được "kết quả **state-of-the-art** trên mười một nhiệm vụ xử lý ngôn ngữ tự nhiên" bao gồm cải thiện điểm GLUE lên 80.5% . **SBERT [11] (Sentence-BERT)**, Reimers và Gurevych đã phát triển Sentence-BERT để giải quyết vấn đề hiệu quả tính toán của BERT. Họ chỉ ra rằng "việc tìm cặp tương tự nhất trong một tập hợp 10.000 câu yêu cầu khoảng 50 triệu phép tính suy luận (65 giờ) với BERT".

Với bộ dữ liệu **ViEcomRec** sử dụng việc chứa nhiều thông tin về sản phẩm là một ưu điểm tuyệt vời để có thể tận dụng được khả năng của các Mô hình Embedding hiện đại này. Nhưng chi phí và tài nguyên tính toán cũng tăng theo khi so với các cách biểu diễn đặc trưng truyền thống bên trên.

Trong nghiên cứu này, để biểu diễn đặc trưng văn bản tiếng Việt, chúng tôi sử dụng hai mô hình embedding tiên tiến được phát triển và tối ưu hóa đặc biệt cho ngôn ngữ tiếng Việt: **dangvantuan/vietnamese-embedding** và **bkai-foundation-models/vietnamese-bi-encoder**. Cả hai đều thuộc nhóm mô hình sentence-transformers, cho phép chuyển đổi câu hoặc đoạn văn bản thành các vector đặc (dense vectors) có khả năng nắm bắt ngữ nghĩa sâu sắc trong ngữ cảnh tiếng Việt.

Vietnamese-Embedding (AITeamVN/Vietnamese_{Embedding})

Mô hình Vietnamese_Embedding là một mô hình nhúng văn bản (*sentence embedding*) được tối ưu hóa từ kiến trúc BGE-M3 (BAAI, 2023) để nâng cao hiệu suất truy xuất thông tin (*information retrieval*) và phân tích ngữ nghĩa (*semantic analysis*) cho tiếng Việt. Mô hình này được phát triển bởi Nguyễn Nho Trung và Nguyễn Nhật Quang (AITeamVN), tập trung

vào việc cải thiện khả năng biểu diễn văn bản tiếng Việt thông qua phương pháp học tương phản (*contrastive learning*).

- Kiến trúc: Dựa trên mô hình **BGE-M3** (BAAI/bge-m3), một mô hình đa chức năng hỗ trợ truy xuất dày đặc (*dense retrieval*), truy xuất đa vector (*multi-vector retrieval*) và truy xuất thưa thớt (*sparse retrieval*).
- Độ dài tối đa: Hỗ trợ chuỗi đầu vào lên đến 2048 tokens.
- Chiều đầu ra: Vector nhúng 1024 chiều.
- Mô hình được huấn luyện trên tập dữ liệu gồm 300,000 bộ ba (*triplets*) tiếng Việt, bao gồm: Truy vấn (*query*), tài liệu tích cực (*positive document*), tài liệu tiêu cực (*negative document*). Phương pháp học tương phản (*contrastive learning*) được áp dụng để tối ưu hóa khả năng phân biệt giữa các văn bản liên quan và không liên quan.
- Ưu điểm: Với hiệu suất vượt trội so với mô hình gốc BGE-M3 và các mô hình khác như dangvantuan/vietnamese-embedding, keepitreal/vietnamese-sbert, ... đều cho kết quả vượt trội.
- Ứng dụng: Truy xuất thông tin, phân loại văn bản, tìm kiếm ngữ nghĩa, hệ thống đề xuất.

Vietnamese-bi-encoder (bkai-foundation-models/vietnamese-bi-encoder)

Mô hình bkai-foundation-models/vietnamese-bi-encoder đại diện cho một tiến bộ quan trọng trong lĩnh vực xử lý ngôn ngữ tự nhiên tiếng Việt, được phát triển bởi BKAI Foundation Models Lab thuộc Trung tâm Nghiên cứu Quốc tế về Trí tuệ Nhân tạo (BKAI) tại Đại học Bách khoa Hà Nội. Đây là một mô hình sentence transformer sử dụng kiến trúc bi-encoder được thiết kế đặc biệt để ánh xạ các câu và đoạn văn tiếng Việt vào không gian vector dày đặc 768 chiều, phục vụ cho các tác vụ như tìm kiếm ngữ nghĩa và phân cụm văn bản.

Mô hình sử dụng kiến trúc bi-encoder, một dạng đặc biệt của Sentence Transformers trong đó hai câu đầu vào được mã hóa độc lập thành các biểu diễn vector có chiều cố định. Khác với cross-encoder xử lý cặp câu cùng lúc, bi-encoder mã hóa từng câu riêng biệt, cho phép tính toán hiệu quả và khả năng mở rộng cao.

- Kiến trúc: Sentence Transformer với backbone PhoBERT-base-v2, một mô hình ngôn ngữ tiền huấn luyện tiên tiến cho tiếng Việt. PhoBERT được phát triển dựa trên kiến trúc RoBERTa, với những cải tiến quan trọng: Sử dụng cấu trúc encoder transformer với các lớp self-attention và feed-forward, Loại bỏ tác vụ Next Sentence Prediction (NSP), huấn luyện với batch size lớn hơn và learning rate cao hơn, Sử dụng byte-level BPE tokenizer, phù hợp với đặc điểm đơn âm tiết của tiếng Việt.
- Đầu vào: 256 tokens
- Kích thước embedding: 768 chiều


- Tính năng: Mã hóa câu và đoạn văn thành vector đặc, hỗ trợ các tác vụ tìm kiếm ngữ nghĩa, phân cụm và nhận diện paraphrase.
- Hiệu năng: Đạt Accuracy@1 lên tới 73.28% và MRR@10 là 80.73% trên bộ dữ liệu thử thách Zalo 2021, vượt trội so với các mô hình SBERT tiếng Việt khác.
- Giới hạn: Giới hạn độ dài đầu vào tối đa 128 tokens, phù hợp với các đoạn văn ngắn đến trung bình.

Dựa vào **Bảng 2.1** có thể nhận thấy tóm tắt chi tiết về 3 phương pháp biểu diễn văn bản. Từ đó có cái nhìn tổng quan giữa 3 giữa 3 phương pháp và có thể kết luận một vài điều ngắn gọn như sau:

- TF-IDF là phương pháp đơn giản, dễ hiểu, hiệu quả cho các tác vụ cơ bản cần tính diễn giải và tài nguyên thấp, nhưng hạn chế về ngữ nghĩa và ngữ cảnh.
- Word Embedding như Word2Vec và FastText cung cấp biểu diễn từ có khả năng nắm bắt mối quan hệ ngữ nghĩa, phù hợp cho các tác vụ trung bình phức tạp và có thể xử lý từ mới tốt hơn TF-IDF.
- Sentence Embedding dựa trên BERT và các biến thể như SBERT mang lại biểu diễn ngữ cảnh sâu sắc, hiệu quả cho các tác vụ NLP phức tạp như hỏi đáp, dịch máy, nhưng đòi hỏi tài nguyên tính toán lớn hơn đáng kể

Bảng 2.1: So sánh các phương pháp biểu diễn văn bản

Tiêu chí	TF-IDF	Word Embedding (Word2Vec, FastText)	Sentence Embedding (BERT, SBERT)
Bản chất biểu diễn	Vector thưa (sparse), trọng số dựa trên tần suất từ và tần suất nghịch đảo tài liệu	Vector đặc (dense), học ngữ nghĩa từ ngữ cảnh qua mạng neural	Vector đặc, biểu diễn ngữ cảnh toàn câu, dựa trên transformer
Khả năng nắm bắt ngữ nghĩa	Thấp, không nắm bắt mối quan hệ ngữ nghĩa giữa các từ	Tốt, nắm bắt được sự tương đồng và quan hệ ngữ nghĩa giữa từ	Rất tốt, hiểu ngữ cảnh toàn câu, xử lý đa nghĩa và ngữ cảnh phức tạp
Xử lý ngữ cảnh	Không, mô hình túi từ (bag-of-words), bỏ qua thứ tự từ	Có, dựa trên ngữ cảnh từ xung quanh trong câu	Có, dựa trên toàn bộ câu và mối quan hệ giữa các từ trong câu
Độ phức tạp tính toán	Thấp, dễ tính toán, không cần huấn luyện phức tạp	Trung bình, cần huấn luyện mạng neural trên corpus lớn	Cao, cần huấn luyện mô hình transformer phức tạp, tốn tài nguyên
Khả năng xử lý từ mới (OOV)	Kém, không thể xử lý từ không có trong corpus	Tốt hơn, đặc biệt FastText xử lý subword giúp giảm OOV	Rất tốt, nhờ biểu diễn ngữ cảnh và mô hình lớn
Ứng dụng phù hợp	Phân loại tài liệu, trích xuất từ khóa, tìm kiếm đơn giản	Phân tích cảm xúc, hệ thống gợi ý, tường thuật, phân loại nâng cao	Các tác vụ phức tạp như hỏi đáp, dịch máy, tổng hợp ngữ nghĩa câu
Khả năng mở rộng	Tốt với tập dữ liệu nhỏ đến vừa, dễ triển khai	Tốt với corpus lớn, có thể tái sử dụng embeddings đã huấn luyện	Khó mở rộng do yêu cầu tính toán và bộ nhớ lớn
Khả năng diễn giải	Cao, trọng số từ có thể giải thích được	Thấp, vector khó diễn giải trực tiếp	Thấp, vector phức tạp và khó giải thích trực tiếp
Hiệu suất trên dữ liệu dài	Tốt hơn trên văn bản dài nhờ nhiều từ đặc trưng	Tốt hơn trên văn bản ngắn hoặc tiêu đề nhờ nắm bắt ngữ nghĩa	Xuất sắc trong mọi độ dài nhờ hiểu ngữ cảnh sâu sắc



Hình 2.3: Ví dụ Cosine Similarity trong không gian 2D

Nguồn: Được lấy trong bài báo của Pavel Praks và cộng sự 2006 tại Hội Nghị IJITEE [12]

2.6 Độ đo tương đồng (Cosine Similarity) trong hệ thống tư vấn

Trong hệ thống đề xuất (Recommendation System) dựa trên nội dung (content-based), **Cosine similarity** là một phương pháp phổ biến để đo độ tương đồng giữa hai đối tượng (ví dụ: sản phẩm hoặc người dùng) dựa trên các đặc trưng (features) của chúng được biểu diễn dưới dạng vector trong không gian đa chiều. Một ví dụ về việc tính toán độ tương đồng giữa các bức ảnh, những bức ảnh được biểu diễn trong không gian 2D, những ảnh có đặc trưng giống nhau sẽ ở gần nhau hơn so với những bức ảnh không có đặc trưng liên quan.

2.6.1 Cosine Similarity là gì?

Cosine similarity đo góc giữa hai vector, cho biết mức độ tương đồng về hướng của chúng, bất kể độ lớn của vector đó. Công thức tính cosine similarity giữa hai vector u và v là:

$$\text{sim}(u, v) = \frac{r_u \cdot r_v}{\|r_u\|_2 \|r_v\|_2} = \frac{\sum_i r_{ui} r_{vi}}{\sqrt{\sum_i r_{ui}^2} \sqrt{\sum_i r_{vi}^2}} \quad (2.17)$$

Trong đó:

- r_u, r_v : là các vector đặc trưng của hai đối tượng.
- $\cdot$: là tích vô hướng (dot product).

- $\|_2$: là chuẩn L2 (độ dài vector).

Giá trị cosine similarity nằm trong khoảng từ -1 đến 1, với 1 thể hiện hai vector hoàn toàn giống nhau về hướng, 0 là không tương đồng, và -1 là hoàn toàn ngược chiều.

2.6.2 Ứng dụng trong hệ thống đề xuất content-based

Trong recommender system content-based, mỗi sản phẩm được mô tả bởi một vector đặc trưng dựa trên thuộc tính như danh mục, mô tả, nguồn gốc, thương hiệu, v.v. Khi người dùng tương tác với một sản phẩm (ví dụ: xem, mua, đánh giá), hệ thống sẽ tính cosine similarity giữa vector đặc trưng của sản phẩm đó với các sản phẩm khác trong kho để tìm ra những sản phẩm tương tự. Tuy là một cách đơn giản nhưng lại mang lại trải nghiệm cá nhân hoá cao mà không đòi hỏi dữ liệu hành vi hay quá nhiều thông tin của người dùng mới làm giảm thiểu hiện tượng **Cold Start**, một vấn đề thường gặp trong Recommender System.

Cosine similarity trong phương pháp content-based recommendation trên thương mại điện tử là phép đo quan trọng giúp xác định mức độ tương đồng giữa các sản phẩm dựa trên đặc trưng của chúng, từ đó đề xuất các sản phẩm phù hợp và cá nhân hóa trải nghiệm người dùng một cách hiệu quả [13]

2.7 Phương pháp đánh giá hệ thống gợi ý

2.7.1 Giới thiệu chung về Đánh giá Hệ thống Gợi ý

Việc đánh giá hiệu quả của hệ thống tư vấn (recommendation systems) là một thách thức quan trọng trong lĩnh vực học máy và khai thác dữ liệu. Các độ đo đánh giá không chỉ phục vụ mục đích kỹ thuật mà còn trở thành yếu tố trung tâm cho thành công kinh doanh của các nền tảng trực tuyến. Một hệ thống gợi ý tốt cần được đánh giá trên nhiều khía cạnh, từ độ chính xác của dự đoán, chất lượng của danh sách gợi ý, đến các yếu tố như tính đa dạng, mới lạ và khả năng đáp ứng nhu cầu của người dùng.

Có nhiều phương pháp tiếp cận để đánh giá hệ thống gợi ý, mỗi phương pháp có những ưu và nhược điểm riêng:

- **Đánh giá Offline (Offline Evaluation):** Thực hiện trên tập dữ liệu lịch sử, không có tương tác người dùng trực tiếp. Đây là phương pháp phổ biến để so sánh và tinh chỉnh thuật toán do tính tiện lợi và chi phí thấp.
- **Đánh giá Online (Online Evaluation / A/B Testing):** Triển khai hệ thống cho người dùng thực và theo dõi các chỉ số tương tác hoặc kinh doanh. Phương pháp này phản ánh hiệu quả thực tế nhất nhưng tốn kém và tiềm ẩn rủi ro.
- **Nghiên cứu Người dùng (User Studies):** Thu thập phản hồi định tính trực tiếp từ người dùng thông qua khảo sát, phỏng vấn để hiểu sâu về trải nghiệm và sự hài lòng.

Trong khuôn khổ đề án này, do các giới hạn về tài nguyên và môi trường thực thi, nhóm sẽ tập trung vào phương pháp **Đánh giá Offline**. Quy trình đánh giá offline của nhóm bao gồm các bước chính: chuẩn bị và phân chia tập dữ liệu ViEcomRec thành tập huấn luyện và tập kiểm thử, huấn luyện các mô hình gợi ý trên tập huấn luyện, tạo gợi ý cho người dùng trong tập kiểm thử, và cuối cùng là tính toán các độ đo hiệu năng bằng cách so sánh gợi ý với dữ liệu thực tế trong tập kiểm thử. Chi tiết về quy trình này và cách xử lý dữ liệu sẽ được trình bày rõ hơn trong Chương 3.

Để đánh giá hiệu năng của các thuật toán gợi ý được triển khai, đặc biệt là cho nhiệm vụ gợi ý top- N sản phẩm, nhóm sẽ phân tích và sử dụng một số độ đo quan trọng, bao gồm **Recall@ k** , **Mean Reciprocal Rank (MRR@ k)**, **Normalized Discounted Cumulative Gain (NDCG@ k)**, và có thể cả **Precision@ k** cũng như **F1-score@ k** để có cái nhìn toàn diện. Các độ đo này sẽ được giải thích chi tiết dưới đây.

2.7.2 Các Độ đo Đánh giá Offline được sử dụng

Recall@ k (Độ phủ tại k) Recall@ k được định nghĩa là tỷ lệ các mục liên quan (relevant items) mà hệ thống tìm thấy được trong số k mục hàng đầu được đề xuất, so với tổng số các mục thực sự liên quan đến người dùng đó trong tập kiểm thử $[?, ?]$. Đây là một độ đo quan trọng để đánh giá khả năng của hệ thống trong việc "truy xuất" hoặc "phủ sóng" được các mục mà người dùng quan tâm $[?]$.

Công thức tính Recall@ k cho một người dùng u là:

$$Recall@k_u = \frac{|\{\text{sp liên quan top-}k \text{ của } u\} \cap \{\text{Tổng sp liên quan của } u \text{ trong tập kiểm thử}\}|}{|\{\text{tổng sp liên quan của } u \text{ trong tập kiểm thử}\}|} \quad (2.18)$$

Và Recall@ k trung bình trên tất cả người dùng trong tập kiểm thử U_{test} là:

$$Recall@k = \frac{1}{|U_{test}|} \sum_{u \in U_{test}} Recall@k_u \quad (2.19)$$

Trong đó, "sản phẩm liên quan" cần được định nghĩa rõ ràng dựa trên dữ liệu kiểm thử (ví dụ: sản phẩm người dùng đã mua, sản phẩm có đánh giá trên một ngưỡng nhất định). Giá trị Recall@ k càng cao cho thấy hệ thống càng tìm được nhiều mục mà người dùng thực sự quan tâm trong số những gợi ý hàng đầu.

Precision@ k (Độ chính xác tại k) Precision@ k đo lường tỷ lệ các mục liên quan trong số k mục hàng đầu được hệ thống gợi ý. Nó cho biết mức độ "chính xác" của các gợi ý trong top- k .

$$Precision@k_u = \frac{|\{\text{Tổng sp trong top-}k \text{ của } u\} \cap \{\text{Tổng sp liên quan của } u \text{ trong tập kiểm thử}\}|}{k} \quad (2.20)$$

Và Precision@ k trung bình trên tất cả người dùng trong tập kiểm thử U_{test} là:

$$Precision@k = \frac{1}{|U_{test}|} \sum_{u \in U_{test}} Precision@k_u \quad (2.21)$$

Precision@k cao có nghĩa là phần lớn các mục trong danh sách gợi ý top-k là hữu ích cho người dùng.

F1-score@k (Điểm F1 tại k) F1-score@k là trung bình điều hòa của Precision@k và Recall@k, cung cấp một thước đo cân bằng duy nhất giữa hai yếu tố này, đặc biệt hữu ích khi có sự đánh đổi giữa chúng.

$$F1@k = 2 \cdot \frac{Precision@k \cdot Recall@k}{Precision@k + Recall@k} \quad (2.22)$$

Giá trị F1@k cao cho thấy hệ thống đạt được sự cân bằng tốt giữa việc gợi ý chính xác và bao phủ được nhiều mục liên quan.

Mean Reciprocal Rank (MRR@k) Mean Reciprocal Rank (MRR) đánh giá hiệu quả của hệ thống dựa trên vị trí (rank) của mục liên quan đầu tiên trong danh sách top-k gợi ý. Đối với mỗi người dùng, Reciprocal Rank (RR) được tính là $1/rank_1$, trong đó $rank_1$ là vị trí của mục liên quan đầu tiên. Nếu không có mục nào liên quan trong top-k, RR được tính là 0. MRR@k là trung bình của các giá trị RR@k này qua tất cả người dùng.

$$RR@k_u = \begin{cases} \frac{1}{rank_{u,1}} & \text{nếu có ít nhất một mục liên quan trong top-k và } rank_{u,1} \text{ là vị trí của mục đó} \\ 0 & \text{ngược lại} \end{cases} \quad (2.23)$$

$$MRR@k = \frac{1}{|U_{test}|} \sum_{u \in U_{test}} RR@k_u \quad (2.24)$$

MRR đặc biệt hữu ích trong các trường hợp mà việc tìm thấy một kết quả tốt đầu tiên là quan trọng nhất (ví dụ: trả lời câu hỏi, tìm kiếm thông tin cụ thể).

Normalized Discounted Cumulative Gain (NDCG@k) Normalized Discounted Cumulative Gain (NDCG) là một độ đo chất lượng xếp hạng tính vi hơn, xem xét cả tính liên quan (relevance) của các mục và vị trí của chúng trong danh sách gợi ý. Các mục liên quan hơn và được xếp ở vị trí cao hơn sẽ đóng góp nhiều hơn vào điểm số.

- **Cumulative Gain (CG@k):** Tổng mức độ liên quan của các mục trong top-k.

$$CG@k_u = \sum_{j=1}^k rel_{uj} \quad (2.25)$$

- **Discounted Cumulative Gain (DCG@k):** CG@k được "chiết khấu"(discounted) bởi vị trí của mục. Các mục ở vị trí thấp hơn sẽ có trọng số chiết khấu lớn hơn.

$$DCG@k_u = \sum_{j=1}^k \frac{rel_{uj}}{\log_2(j+1)} \quad (2.26)$$

trong đó rel_{uj} là mức độ liên quan của sản phẩm ở vị trí j trong danh sách gợi ý cho người dùng u . Mức độ liên quan có thể là nhị phân (0 hoặc 1) hoặc đa cấp (ví dụ: từ 1 đến 5).

- **Ideal Discounted Cumulative Gain (IDCG@k):** Là giá trị DCG@k tối đa có thể đạt được cho người dùng u , khi danh sách gợi ý được sắp xếp một cách hoàn hảo (các mục liên quan nhất ở vị trí cao nhất).
- **Normalized Discounted Cumulative Gain (NDCG@k):** DCG@k được chuẩn hóa bằng cách chia cho IDCG@k, đưa giá trị về khoảng $[0, 1]$.

$$NDCG@k_u = \frac{DCG@k_u}{IDCG@k_u} \quad (2.27)$$

Và NDCG@k trung bình trên tất cả người dùng là:

$$NDCG@k = \frac{1}{|U_{test}|} \sum_{u \in U_{test}} NDCG@k_u \quad (2.28)$$

NDCG@k là một độ đo mạnh mẽ vì nó xem xét cả thứ tự và mức độ liên quan của các mục được gợi ý.

(Nếu có dự đoán rating) Độ đo Chính xác Dự đoán Đánh giá Nếu hệ thống của bạn cũng thực hiện nhiệm vụ dự đoán giá trị đánh giá cụ thể (ví dụ: dự đoán người dùng sẽ đánh giá một sản phẩm bao nhiêu sao), các độ đo sau sẽ được sử dụng:

- **Mean Absolute Error (MAE):** Đo lường độ lớn trung bình của sai số tuyệt đối giữa đánh giá dự đoán và đánh giá thực tế.

$$MAE = \frac{1}{|S_{test}|} \sum_{(u,i) \in S_{test}} |R_{ui} - \hat{R}_{ui}| \quad (2.29)$$

- **Root Mean Squared Error (RMSE):** Tương tự MAE nhưng "phạt" các lỗi lớn nặng hơn do bình phương sai số.

$$RMSE = \sqrt{\frac{1}{|S_{test}|} \sum_{(u,i) \in S_{test}} (R_{ui} - \hat{R}_{ui})^2} \quad (2.30)$$

Trong đó S_{test} là tập các cặp (người dùng, mục) có đánh giá thực tế trong tập kiểm thử, R_{ui} là đánh giá thực tế và $\hat{R}_{ui}$ là đánh giá dự đoán.

Lựa chọn giá trị k và Định nghĩa "Sản phẩm liên quan" Việc lựa chọn giá trị k (ví dụ: $k = 5, 10, 20$) cho các độ đo top-N phụ thuộc vào kịch bản sử dụng. Ví dụ, nếu giao diện người dùng chỉ hiển thị 5 gợi ý, việc đánh giá với $k = 5$ sẽ quan trọng. Định nghĩa "sản phẩm liên quan" cũng rất quan trọng. Đối với dữ liệu tương minh như ViEcomRec, "sản phẩm liên quan" có thể là những sản phẩm mà người dùng đã đánh giá từ 4 sao trở lên trong tập kiểm thử. Đối với dữ liệu ngầm định, nó có thể là những sản phẩm người dùng đã mua hoặc tương tác tích cực. Nhóm sẽ định nghĩa rõ ràng tiêu chí này trong quá trình thực nghiệm

Chương 4 của bạn Kết quả chi tiết của các độ đo này cho từng thuật toán/mô hình được triển khai sẽ được trình bày và phân tích kỹ lưỡng trong Chương 4.

Chương 3

Dữ liệu và phương pháp triển khai

3.1 Mô tả tập dữ liệu ViEcomRec

Trong đồ án này, nhóm sử dụng tập dữ liệu **ViEcomRec** [4] để xây dựng và đánh giá hệ thống gợi ý sản phẩm. ViEcomRec là một tập dữ liệu mới, được thiết kế đặc biệt cho bài toán gợi ý trong lĩnh vực thương mại điện tử (e-commerce) tại thị trường Việt Nam, tập trung vào danh mục sản phẩm sữa rửa mặt. Đây là một đóng góp quan trọng vì các tập dữ liệu công khai cho thị trường và ngôn ngữ tiếng Việt còn hạn chế, trong khi các đặc điểm địa phương và ngôn ngữ có ảnh hưởng đáng kể đến hành vi mua sắm và hiệu quả của hệ thống gợi ý.

3.1.1 Nguồn gốc và Mục tiêu của Tập dữ liệu

Tập dữ liệu ViEcomRec được xây dựng nhằm giải quyết bài toán gợi ý sản phẩm trên các nền tảng thương mại điện tử, một lĩnh vực có sự tăng trưởng mạnh mẽ trong những năm gần đây. Các tác giả của ViEcomRec nhận thấy rằng, mặc dù có nhiều nghiên cứu về hệ thống gợi ý, nhưng các tập dữ liệu và mô hình thường tập trung vào ngôn ngữ tiếng Anh và các thị trường quốc tế lớn như Amazon. Trong khi đó, thị trường Việt Nam với những đặc thù riêng về ngôn ngữ và hành vi người dùng lại chưa có nhiều tài nguyên tương tự.

Mục tiêu chính của việc xây dựng ViEcomRec là:

- Cung cấp một tập dữ liệu chuẩn (benchmark dataset) cho cộng đồng nghiên cứu về hệ thống gợi ý tại Việt Nam.
- Khám phá và đánh giá hiệu quả của các phương pháp gợi ý khác nhau (từ lọc dựa trên nội dung đến lọc dựa trên thuộc tính) trên dữ liệu tiếng Việt thực tế.
- Tạo điều kiện cho việc phát triển các hệ thống gợi ý phù hợp hơn với đặc thù của thị trường thương mại điện tử Việt Nam.

Tập dữ liệu này tập trung vào sản phẩm **sữa rửa mặt**, một mặt hàng thu hút sự quan tâm đáng kể từ cả nam và nữ giới và có số lượng giao dịch lớn trên các sàn thương mại điện tử.

3.1.2 Quy trình Thu thập Dữ liệu (Dataset Crawling)

Dữ liệu cho ViEcomRec được thu thập từ **Shopee Việt Nam**, một trong những nền tảng thương mại điện tử lớn và phổ biến tại Việt Nam. Quy trình thu thập bao gồm các bước chính:

1. **Thu thập thông tin sản phẩm:** Sử dụng các công cụ như BeautifulSoup và Selenium viết bằng Python, nhóm tác giả đã thu thập thông tin chi tiết của các sản phẩm sữa rửa mặt. Tổng cộng có **2,244 mục (items)** sản phẩm sữa rửa mặt được thu thập.
2. **Thu thập đánh giá và tương tác:** Từ thông tin các sản phẩm, nhóm tác giả tiếp tục thu thập các đánh giá (reviews) của người dùng, bao gồm nội dung đánh giá, điểm xếp hạng (ratings), và thông tin thời gian (date-time). Một điểm đáng chú ý là Shopee chỉ cho phép người dùng đánh giá sản phẩm sau khi đã thực hiện giao dịch mua hàng, do đó các đánh giá này phản ánh tương tác mua hàng thực tế.

Kết quả, tập dữ liệu ghi nhận được **369,099 lượt tương tác (interactions/reviews)** từ **304,708 người dùng (users)** khác nhau.

3.1.3 Trích xuất Thuộc tính Sản phẩm (Attribute Extraction)

Mô tả sản phẩm trên các trang thương mại điện tử thường dài và chứa nhiều thông tin. Để có được các đặc trưng hữu ích cho việc gợi ý, các tác giả đã thực hiện một bước trích xuất thuộc tính.

- **Các thuộc tính được trích xuất:** Tổng cộng có 9 thuộc tính chính được trích xuất từ mô tả sản phẩm, bao gồm:
 1. Tên sản phẩm (item name)
 2. Thành phần (ingredient)
 3. Đặc điểm sản phẩm (product_feature)
 4. Loại da phù hợp (skin_type)
 5. Dung tích/Trọng lượng (capacity)
 6. Thiết kế/Bao bì (design)
 7. Thương hiệu (brand)
 8. Hạn sử dụng (expiry)
 9. Nguồn gốc/Xuất xứ (origin)

Các thuộc tính này bao quát hầu hết các khía cạnh mà người dùng thường quan tâm khi mua sản phẩm sữa rửa mặt.

- **Công cụ hỗ trợ trích xuất:** Mô hình ngôn ngữ lớn **InstructGPT** của OpenAI đã được sử dụng để tự động hóa quá trình trích xuất thuộc tính từ các đoạn mô tả dài.

- **Đảm bảo chất lượng:** Sau khi trích xuất tự động, một người đánh giá (annotator) đã kiểm tra lại thủ công để đảm bảo tính chính xác và sửa các lỗi sai (nếu có).

Toàn bộ dữ liệu đã được trích xuất và tiền xử lý được công bố công khai tại kho lưu trữ GitHub: https://github.com/linh222/face_cleanser_recommendation_dataset.

3.1.4 Thống kê Tập dữ liệu

Bảng 3.1 (tham chiếu đến Bảng 1 trong bài báo gốc) tóm tắt các thông số chính của tập dữ liệu ViEcomRec sau khi được chia thành tập huấn luyện, tập kiểm định và tập kiểm thử theo giao thức "leave-one-out".

Bảng 3.1: Thống kê tập dữ liệu ViEcomRec.

Tập dữ liệu	Số người dùng	Số mục	Số tương tác
Huấn luyện (Train)	304,708	2,244	358,591
Kiểm định (Validation)	3,592	900	5,254
Kiểm thử (Test)	3,592	862	5,254


Đặc điểm nổi bật của ViEcomRec:

- **Tính đặc thù cho thị trường Việt Nam:** Cung cấp dữ liệu thực tế từ một nền tảng e-commerce phổ biến tại Việt Nam.
- **Tập trung vào một danh mục cụ thể:** Việc tập trung vào sản phẩm sữa rửa mặt giúp kiểm soát các yếu tố và đánh giá sâu hơn hiệu quả của các thuật toán.
- **Dữ liệu tương tác thực tế:** Các đánh giá được thu thập từ người dùng đã mua hàng.
- **Thông tin thuộc tính phong phú:** Việc trích xuất 9 thuộc tính sản phẩm cho phép xây dựng các mô hình gợi ý dựa trên nội dung một cách hiệu quả.
- **Công khai và có sẵn:** Giúp thúc đẩy nghiên cứu và phát triển trong lĩnh vực hệ thống gợi ý cho ngôn ngữ và thị trường Việt Nam.


Dữ liệu này là nền tảng để nhóm triển khai các phương pháp được trình bày trong các phần tiếp theo của đề án.

3.2 Khám Phá Dữ liệu (EDA)

3.2.1 Phân phối về giá và đánh giá sản phẩm




Hình 3.1: Phân phối của giá sản phẩm trong tập dữ liệu.



Hình 3.2: Phân phối về lượng đánh giá trung bình của sản phẩm.

3.2.2 Mối liên hệ giữa các thuộc tính



Hình 3.3: Mối liên hệ giữa giá và số lượng bán ra.

3.3 Chuẩn bị dữ liệu

3.3.1 Xây dựng dữ liệu cho Lọc dựa trên nội dung

Để triển khai phương pháp Lọc dựa trên nội dung (Content-Based Filtering - CBF), nhóm đã thực hiện các bước chuẩn bị dữ liệu sau:

1. **Lọc người dùng hoạt động:** Từ tệp `data_reviews_purchase.csv`, nhóm đã lọc ra những người dùng có tối thiểu 3 lượt tương tác để đảm bảo có đủ dữ liệu cho việc đánh giá mô hình. Sau khi lọc, còn lại **3,952** người dùng.
2. **Tạo bảng tương tác:** Dữ liệu của những người dùng này được sắp xếp theo thời gian tương tác giảm dần để phục vụ cho việc chia tập train/test/validation sau này. Một ví dụ về dữ liệu tương tác được thể hiện trong Bảng 3.2.
3. **Xây dựng nội dung sản phẩm:** Từ tệp `data_product.csv`, nhóm đã kết hợp các trường văn bản quan trọng (tên sản phẩm, thương hiệu, loại da, mô tả đã xử lý,...) thành một trường văn bản duy nhất là `combined_text` cho mỗi sản phẩm. Trường này sau đó được làm sạch và chuẩn bị cho bước vector hóa.

Bảng 3.2: Ví dụ dữ liệu tương tác người dùng và sản phẩm.

user_id	product_id	cmt_date
295796	2221	2022-12-21 06:46:28
295796	1951	2022-09-19 07:23:34
295796	1886	2022-11-18 06:39:16
290595	1814	2022-11-12 12:03:30
290595	1768	2022-12-13 13:23:02

3.3.2 Xây dựng dữ liệu sản phẩm phổ biến

Để giải quyết vấn đề khởi động nguội (cold-start), nhóm đã xây dựng một danh sách các sản phẩm phổ biến. Điểm phổ biến (Popularity Score) được tính toán dựa trên sự kết hợp có trọng số của các yếu tố: số lượt bán, điểm sao trung bình và số lượt đánh giá, theo công thức tại phương trình 3.1.

$$\begin{aligned}
 \text{Popularity Score} = & 0.5 \times \frac{\text{num_sold_time}}{\max(\text{num_sold_time})} \\
 & + 0.3 \times \frac{\text{avg_star}}{\max(\text{avg_star})} \\
 & + 0.2 \times \frac{\text{num_rating}}{\max(\text{num_rating})}
 \end{aligned} \tag{3.1}$$

Phân phối của điểm phổ biến được thể hiện trong Hình ???. Dựa trên phân phối này, nhóm đã chọn ngưỡng 0.3 để xác định các sản phẩm phổ biến. Kết quả, có **725** sản phẩm được xem là phổ biến nhất, sẵn sàng để đề xuất cho người dùng mới.

3.4 Các phương pháp và mô hình triển khai

Trong khuôn khổ đồ án, nhóm đã triển khai và đánh giá ba phương pháp chính: Lọc dựa trên nội dung, Đề xuất dựa trên độ phổ biến, và Lọc cộng tác dựa trên người dùng. Các phương pháp này sau đó được kết hợp để tạo thành một mô hình lai toàn diện.

3.4.1 Áp dụng Lọc dựa trên nội dung (Content-Based Filtering)

Phương pháp này tập trung vào việc phân tích đặc trưng văn bản của sản phẩm để tìm ra sự tương đồng.

- Thiết kế đặc trưng:** Dữ liệu nội dung từ các trường như `product_name`, `brand`, `description`... được tổng hợp thành một trường duy nhất là `combined_text`.
- Tạo Vector Embedding:** Chuỗi `combined_text` sau đó được đưa vào mô hình embedding (như TF-IDF hoặc Sentence-BERT) để chuyển đổi mỗi sản phẩm thành một vector số học.

3. **Tính toán ma trận tương đồng:** Ma trận tương đồng item-item được tính toán bằng cách áp dụng độ đo **Cosine Similarity** trên các vector sản phẩm. Ma trận này chính là "bộ não" của hệ thống CBF, cho phép tìm kiếm nhanh chóng các sản phẩm tương tự nhau về mặt nội dung.

3.4.2 Áp dụng Lọc cộng tác dựa trên người dùng (User-Based CF)

Phương pháp này hoạt động dựa trên nguyên lý "những người dùng có cùng sở thích sẽ thích những sản phẩm tương tự".

1. **Xây dựng ma trận User-Item:** Từ dữ liệu tương tác, một ma trận thưa được tạo ra với người dùng là hàng, sản phẩm là cột, và giá trị là điểm rating.
2. **Chuẩn hóa dữ liệu:** Để loại bỏ thiên vị, điểm rating của mỗi người dùng được chuẩn hóa bằng cách trừ đi giá trị trung bình (Mean-Centering).
3. **Tính toán ma trận tương đồng:** Độ tương quan Pearson (tương đương Cosine Similarity trên dữ liệu đã chuẩn hóa) được sử dụng để tính toán ma trận tương đồng user-user.
4. **Dự đoán và Gợi ý:** Hệ thống tìm các "láng giềng" tương đồng để dự đoán rating cho các sản phẩm chưa được đánh giá và đưa ra gợi ý.

3.4.3 Áp dụng Đề xuất dựa trên độ phổ biến (Popularity-Based)

Đây là phương pháp cơ sở, đóng vai trò quan trọng trong việc giải quyết vấn đề "khởi động nguội" cho người dùng mới.


1. **Tính toán Popularity Score:** Một điểm số phổ biến được tính cho mỗi sản phẩm dựa trên công thức trọng số của lượt bán, sao trung bình và số lượt đánh giá.
2. **Xây dựng Bảng xếp hạng:** Các sản phẩm được sắp xếp theo popularity_score từ cao đến thấp và được lưu lại. Quá trình này được thực hiện offline và cập nhật định kỳ.
3. **Gợi ý:** Khi người dùng mới truy cập, hệ thống sẽ trả về Top-K sản phẩm từ bảng xếp hạng đã được tính toán sẵn. Sơ đồ hoạt động được mô tả trong Hình ??.

3.4.4 Xây dựng mô hình lai (Hybrid Model)

Để tận dụng thế mạnh của nhiều phương pháp, nhóm đã thiết kế một mô hình lai. Cấu trúc của mô hình được thiết kế để:

- **Đối với người dùng mới (New User):** Hệ thống sẽ ưu tiên đề xuất các sản phẩm từ danh sách phổ biến hoặc dựa trên nội dung của một truy vấn tìm kiếm (nếu có).


- **Đối với người dùng cũ (Old User):** Hệ thống sẽ kết hợp kết quả từ Lọc dựa trên nội dung (CBF) và Lọc cộng tác (CF) để đưa ra gợi ý cuối cùng, mang tính cá nhân hóa cao. Kiến trúc này được minh họa trong Hình 3.4.



Hình 3.4: Mô hình lai áp dụng cho người dùng cũ.


3.5 Thiết kế Hệ thống tổng thể

Luồng hoạt động tổng thể của hệ thống đề xuất được thể hiện trong Hình 3.5. Hệ thống bắt đầu từ việc tiền xử lý dữ liệu, tạo và lưu trữ các vector embedding và ma trận tương tác. Khi có yêu cầu từ người dùng (tìm kiếm hoặc tương tác), hệ thống sẽ áp dụng logic của mô hình lai để tạo ra một danh sách sản phẩm được đề xuất.



Hình 3.5: Tổng quan luồng hoạt động của hệ thống đề xuất.

Kiến trúc của hệ thống bao gồm một Frontend (giao diện web) và một Backend (xây dựng bằng FastAPI), như mô tả trong Hình 3.6. Frontend chịu trách nhiệm tương tác với người dùng, trong khi Backend xử lý các yêu cầu, thực hiện các thuật toán gợi ý và truy xuất dữ liệu cần thiết.



Hình 3.6: Kiến trúc hệ thống đề xuất.

Chương 4

Thực nghiệm và đánh giá

Chương này trình bày chi tiết về quá trình thực nghiệm và các kết quả đánh giá hiệu quả của các phương pháp đề xuất đã được triển khai, bao gồm Lọc dựa trên nội dung (Content-Based Filtering), Đề xuất dựa trên độ phổ biến (Popularity-Based Recommendation) và Lọc cộng tác dựa trên người dùng (User-Based Collaborative Filtering).

4.1 Mô tả kịch bản thực nghiệm

Để đánh giá một cách khách quan, nhóm đã tiến hành chia tập dữ liệu theo phương pháp "leave-one-out" dựa trên yếu tố thời gian. Cụ thể, với mỗi người dùng có trong tập dữ liệu tương tác, lượt tương tác gần đây nhất được đưa vào tập kiểm thử (Test set), lượt tương tác gần thứ hai được đưa vào tập kiểm định (Validation set), và tất cả các tương tác còn lại được sử dụng cho tập huấn luyện (Train set).

Các mô hình được huấn luyện trên tập Train, sau đó các siêu tham số được tinh chỉnh trên tập Validation. Cuối cùng, hiệu quả của mô hình với bộ tham số tốt nhất sẽ được đánh giá trên tập Test.

Đối với các mô hình đề xuất danh sách xếp hạng (ranking), nhóm sử dụng các độ đo phổ biến như **Recall@k**, **Precision@k**, **MRR@k** và **NDCG@k** với $k = 10$. Đối với mô hình dự đoán điểm đánh giá (rating prediction) như User-Based CF, nhóm sử dụng **MAE** (Mean Absolute Error) và **RMSE** (Root Mean Squared Error).

4.2 Thiết lập và thông số mô hình

- **Lọc dựa trên nội dung:** Sử dụng mô hình AlTeamVN/Vietnamese-Embedding để vector hóa thuộc tính `combined_text` của sản phẩm. Độ tương đồng được tính bằng Cosine Similarity.
- **Đề xuất dựa trên độ phổ biến:** Điểm phổ biến (Popularity Score) được tính dựa trên công thức đã nêu ở mục 3.3.2, kết hợp số lượt bán, điểm sao trung bình và số lượt đánh giá.

- **Lọc cộng tác dựa trên người dùng:** Sử dụng độ tương đồng Pearson Correlation Coefficient. Dữ liệu được chuẩn hóa bằng phương pháp Mean-Centering.

4.3 Kết quả gợi ý với phương pháp lọc nội dung

Phương pháp lọc dựa trên nội dung được đánh giá trên tập kiểm thử và cho ra kết quả như sau:

- **Recall@10:** 0.171
- **Precision@10:** 0.017
- **MRR@10:** 0.062
- **NDCG@10:** 0.230

Nhận xét: Kết quả cho thấy mô hình Lọc dựa trên nội dung có chất lượng xếp hạng khá tốt, thể hiện qua chỉ số NDCG@10 đạt 0.230. Điều này có nghĩa là các sản phẩm thực sự liên quan có xu hướng được xếp ở các vị trí cao trong danh sách gợi ý. Tuy nhiên, Precision@10 khá thấp (0.017), cho thấy trong top 10 gợi ý có ít sản phẩm mà người dùng thực sự tương tác. Recall@10 ở mức 0.171 cho thấy mô hình có khả năng "phủ" được một phần các sản phẩm mà người dùng quan tâm.

4.4 Kết quả gợi ý với phương pháp Đề xuất dựa trên độ phổ biến

Phương pháp đề xuất các sản phẩm phổ biến nhất (một baseline quan trọng) cho kết quả như sau:

- **Recall@10:** 0.149
- **Precision@10:** 0.015
- **MRR@10:** 0.053
- **NDCG@10:** 0.089

Nhận xét: Là một phương pháp đơn giản không cá nhân hóa, mô hình dựa trên độ phổ biến cho kết quả thấp hơn so với Lọc nội dung ở hầu hết các chỉ số, đặc biệt là NDCG@10 (0.089 so với 0.230). Điều này khẳng định tầm quan trọng của việc cá nhân hóa gợi ý dựa trên đặc trưng sản phẩm. Tuy nhiên, mô hình này vẫn là một giải pháp hiệu quả cho vấn đề khởi động nguội (cold-start) khi chưa có thông tin về người dùng.

4.5 Đánh giá hiệu quả Mô hình Lọc cộng tác

Đối với phương pháp Lọc cộng tác dựa trên người dùng (User-Based CF), nhiệm vụ chính là dự đoán điểm đánh giá (rating) mà một người dùng sẽ dành cho một sản phẩm. Do đó, các độ đo lỗi được sử dụng:

- **Mean Absolute Error (MAE):** 0.055
- **Root Mean Squared Error (RMSE):** 0.291

Nhận xét: Giá trị MAE là 0.055 cho thấy sai số trung bình tuyệt đối giữa dự đoán và đánh giá thực tế là rất nhỏ. Chỉ số RMSE cao hơn đáng kể (0.291) cho thấy mô hình có xu hướng tạo ra một số lỗi dự đoán lớn, nhưng nhìn chung, hiệu suất dự đoán của mô hình là khá tốt trên tập dữ liệu đã được lọc.

4.6 Nhận xét và phân tích kết quả

Để so sánh hiệu quả giữa các phương pháp đề xuất xếp hạng, ta có bảng tổng hợp sau:

Bảng 4.1: So sánh hiệu quả giữa các phương pháp đề xuất xếp hạng.

Độ đo	Lọc dựa trên nội dung	Đề xuất dựa trên độ phổ biến
NDCG@10	0.230	0.089
Recall@10	0.171	0.149
MRR@10	0.062	0.053
Precision@10	0.017	0.015

Qua bảng 4.1, có thể thấy rõ ràng rằng phương pháp **Lọc dựa trên nội dung** vượt trội hơn hẳn so với phương pháp **Đề xuất dựa trên độ phổ biến** trên mọi chỉ số đánh giá. Điều này chứng tỏ việc phân tích và tận dụng các thuộc tính chi tiết của sản phẩm (như thương hiệu, loại da, thành phần) mang lại khả năng cá nhân hóa cao và chính xác hơn, giúp hệ thống gợi ý được những sản phẩm phù hợp hơn với nhu cầu của từng người dùng.

Chương 5

Thảo luận và Kết luận

5.1 Thảo luận

Mỗi phương pháp được triển khai trong đồ án đều có những ưu, nhược điểm và vai trò riêng trong một hệ thống lai hoàn chỉnh. Việc hiểu rõ các đặc tính này là rất quan trọng để có thể kết hợp chúng một cách hiệu quả. Bảng 5.1 dưới đây tóm tắt và so sánh ba phương pháp chính đã được thực nghiệm.

Bảng 5.1: So sánh tổng quan các phương pháp đề xuất.

Tiêu chí	Lọc dựa trên Nội dung (Content-Based)	Lọc Cộng tác (Collaborative Filtering)	Đề xuất dựa trên Độ phổ biến (Popularity)
Nguyên lý hoạt động	"Gợi ý những sản phẩm có nội dung tương tự với những gì bạn đã thích."	"Gợi ý những sản phẩm mà những người giống bạn cũng thích."(User-Based)	"Gợi ý những sản phẩm đang 'hot' nhất và được nhiều người mua nhất."
Ưu điểm	- Cá nhân hóa cao. - Không bị Cold-Start với sản phẩm mới. - Dễ diễn giải.	- Khả năng khám phá bất ngờ (Serendipity). - Không cần dữ liệu chi tiết về sản phẩm.	- Rất đơn giản, nhanh. - Giải quyết tốt vấn đề Cold-Start cho người dùng mới. - Phản ánh đúng xu hướng thị trường.
Hạn chế (Nhược điểm)	- Bị giới hạn trong "bong bóng lọc"(Filter Bubble). - Phụ thuộc vào chất lượng trích xuất đặc trưng.	- Bị Cold-Start nặng với người dùng và sản phẩm mới. - Vấn đề dữ liệu thưa (Sparsity) làm giảm hiệu quả. - Khả năng mở rộng kém.	- Hoàn toàn không cá nhân hóa. - Thiên vị các sản phẩm cũ, phổ biến (Popularity Bias). - Dễ bị thao túng.
Khi nào nên dùng?	Khi có dữ liệu metadata phong phú về sản phẩm (như bài toán của nhóm).	Khi có lượng lớn dữ liệu tương tác (ratings, clicks, purchases).	Làm baseline, giải quyết Cold-Start, hoặc là một thành phần trong mô hình lai.

5.2 Kết luận

Qua quá trình thực hiện đồ án, nhóm đã đạt được các mục tiêu chính đề ra. Đồ án đã xây dựng và đánh giá thành công một hệ thống tư vấn lai cho sản phẩm sữa rửa mặt trên nền tảng thương mại điện tử, sử dụng tập dữ liệu ViEcomRec.

Nhóm đã triển khai và so sánh ba phương pháp cốt lõi: Lọc dựa trên nội dung, Lọc cộng tác và Đề xuất dựa trên độ phổ biến. Kết quả thực nghiệm cho thấy phương pháp Lọc dựa trên nội dung, với việc tận dụng các kỹ thuật embedding ngôn ngữ hiện đại, đã cho thấy hiệu quả vượt trội trong việc cá nhân hóa và đưa ra các gợi ý có chất lượng xếp hạng cao. Các phương pháp còn lại cũng đã chứng minh được vai trò của mình, đặc biệt là trong việc giải quyết vấn đề khởi động nguội và làm baseline so sánh.

Đồ án không chỉ áp dụng kiến thức lý thuyết vào một bài toán thực tế mà còn xây dựng được một luồng xử lý dữ liệu và mô hình hoàn chỉnh, có tiềm năng ứng dụng và phát triển trong tương lai.

5.3 Hướng phát triển

Để tiếp tục hoàn thiện và nâng cao hiệu quả của hệ thống, nhóm đề xuất các hướng phát triển trong tương lai như sau:

- Cải tiến mô hình:

- Nghiên cứu và triển khai các mô hình Collaborative Filtering phức tạp hơn (ví dụ: Model-Based CF như Matrix Factorization, hoặc các mô hình Deep Learning như Neural Collaborative Filtering) để cải thiện độ chính xác.
- Khám phá các kỹ thuật kết hợp lai nâng cao (ví dụ: blending, cascading, feature-level hybrid) để tối ưu hóa việc kết hợp kết quả từ các mô hình con.
- Tích hợp thêm các đặc trưng người dùng (độ tuổi, giới tính, lịch sử duyệt web) để cá nhân hóa sâu hơn.

- Dữ liệu và đánh giá:

- Thu thập thêm dữ liệu tương tác người dùng để giải quyết vấn đề dữ liệu thưa thớt, nâng cao hiệu suất của các mô hình Lọc cộng tác.
- Thực hiện A/B testing trong môi trường thực tế để đánh giá hiệu quả kinh doanh của hệ thống.
- Khám phá các độ đo đánh giá đa dạng hơn như diversity, novelty, serendipity để đảm bảo các gợi ý không chỉ chính xác mà còn thú vị.

- Mở rộng ứng dụng:

- Mở rộng hệ thống để gợi ý các nhóm sản phẩm mỹ phẩm hoặc chăm sóc cá nhân khác.

- Xây dựng hệ thống khuyến nghị thời gian thực (real-time) để phản ứng ngay lập tức với hành vi của người dùng.
- Phát triển giao diện người dùng tương tác hơn, cho phép người dùng tùy chỉnh hoặc cung cấp phản hồi trực tiếp về các gợi ý.

Tài liệu tham khảo

- [1] M. J. Pazzani and D. Billsus, “Content-based recommendation systems,” in *The adaptive web: methods and strategies of web personalization*. Springer, 2007, pp. 325–341.
- [2] Y. Koren, R. Bell, and C. Volinsky, “Matrix factorization techniques for recommender systems,” *Computer*, vol. 42, no. 8, pp. 30–37, 2009.
- [3] S. Trewin, “Knowledge-based recommender systems,” *Encyclopedia of library and information science*, vol. 69, no. Supplement 32, p. 180, 2000.
- [4] Q.-L. Tran, B. T. Nguyen, G. J. Jones, and C. Gurrin, “Viecomrec: A dataset for recommendation in vietnamese e-commerce,” in *International Conference on Computational Data and Social Networks*. Springer, 2023, pp. 74–82.
- [5] L. Lee, “Idf revisited: a simple new derivation within the robertson-spärck jones probabilistic model,” in *Proceedings of the 30th annual international ACM SIGIR conference on Research and development in information retrieval*, 2007, pp. 751–752.
- [6] I. Lumintu, “Content-based recommendation engine using term frequency-inverse document frequency vectorization and cosine similarity: A case study,” in *2023 IEEE 9th Information Technology International Seminar (ITIS)*, 2023, pp. 1–6.
- [7] T. Mikolov, K. Chen, G. Corrado, and J. Dean, “Efficient estimation of word representations in vector space,” *arXiv preprint arXiv:1301.3781*, 2013.
- [8] T. Mikolov, E. Grave, P. Bojanowski, C. Puhersch, and A. Joulin, “Advances in pre-training distributed word representations,” *arXiv preprint arXiv:1712.09405*, 2017.
- [9] X. Rong, “word2vec parameter learning explained,” *arXiv preprint arXiv:1411.2738*, 2014.
- [10] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, “Bert: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, 2019, pp. 4171–4186.
- [11] N. Reimers and I. Gurevych, “Sentence-bert: Sentence embeddings using siamese bert-networks,” *arXiv preprint arXiv:1908.10084*, 2019.

- [12] P. Praks, L. Machala, V. Snášel, and M. Střížík, “Intelligent information retrieval using numerical linear algebra and applications,” in *International Symposium GIS Ostrava*, 2006, pp. 23–25.
- [13] C. Fiarni and H. Maharani, “Product recommendation system design using cosine similarity and content-based filtering methods,” *IJITEE (International Journal of Information Technology and Electrical Engineering)*, vol. 3, no. 2, pp. 42–48, 2019.